Cechy sygnału audio w dziedzinie częstotliwości

Dominik Zieliński, Mateusz Stawicki

30 kwietnia 2026

Repozytorium: `https://github.com/xxxDKGxxx/JuceFrequencyAnalysis`

Spis treści

1 Wstęp **4**

2 Opis aplikacji **5**

2.1 Technologie i środowisko 5

2.2 Interfejs użytkownika 5

3 Opis zaimplementowanych funkcjonalności **7**

3.1 Wczytywanie i reprezentacja sygnału 7

3.2 Analiza ramkowa 8

3.3 Cyfrowe przetwarzanie sygnałów w dziedzinie częstotliwości 8

3.4 Funkcje okienkowe i okienkowanie 8

Okno Prostokątne (Rectangular) 8

Okno Trójkątne (Bartlett) 9

Okno Hanna (Hann / van Hann) 9

Okno Hamminga 9

Okno Blackmana 9

Okno Nuttalla 9

3.5 Parametry widmowe sygnału (Frame-Level Features) 10

3.6 Analiza cepstralna i ton podstawowy F_0 10

3.7 Spektrogram 11

Wizualizacja w skali decybelowej (dB) 11

Matematyczna konwersja na dB 11

Normalizacja i zakres dynamiczny 12

Zalety prezentacji w dB 12

4 Przeprowadzone eksperymenty **12**

4.1 Porównanie parametrów dla różnych głosów 12

Ogólne obserwacje na przestrzeni próbek 12

Środek ciężkości widma 13

Efektywne pasmo 14

Miara płaskości widma 14

Spektralny współczynnik szczytu 15

4.2 Formanty 15

Rola formantów w rozpoznawaniu głosek 15

Zmienność formantów 16
Wartości formantów różnych samogłosek 16
Wybór okna Hamminga do analizy formantów 16
Formanty w „a” 17
Formanty w „i” 17
Formanty w „o” 20
Formanty w „u” 20
Formanty u różnych speakerów 22
4.3 Zbadanie wpływu funkcji okienkowych 23
Bliskie częstotliwości 23
Różne amplitudy 27
4.4 Porównanie wyznaczania F_0 metodą cepstralną oraz autokorelacyjną . . . 31
4.5 Zmiana tonu podstawowego u jednego lektora dla różnych słów 33
4.6 Spektogramy różnych słów 35

5 Wnioski **37**
5.1 Zbadanie wpływu funkcji okienkowych 37
Eksperyment bliskich częstotliwości 37
Eksperyment różnych amplitud 37
5.2 Wnioski z analizy parametrów w dziedzinie częstotliwości 38
5.3 Wnioski z analizy formantów 39
5.4 Wnioski z analizy spektrogramów 39

1 Wstęp

Celem projektu było opracowanie aplikacji okienkowej przeznaczonej do analizy sygnału audio w dziedzinie częstotliwości. Program umożliwia wczytywanie plików w formacie `.wav`, wizualizację przebiegu czasowego sygnału a także analizę ramkową parametrów w dziedzinie częstotliwości dla różnych wielkości ramek oraz różnych funkcji okna. Dodatkowo aplikacja renderuje spektogram audio a także wyznacza częstotliwość tonu podstawowego używając do tego funkcji cepstrum.

2 Opis aplikacji

2.1 Technologie i środowisko

Aplikacja została wykonana w języku C++ jako program okienkowy. Ze względu na charakter projektu wybrano środowisko umożliwiające jednoczesną obsługę interfejsu graficznego oraz wygodne operacje na danych audio. Projekt jest związany z frameworkiem JUCE i zawiera konfigurację typową dla aplikacji C++/JUCE.

Element	**Zastosowanie**	**Uzasadnienie wyboru**
Język programowania C++	implementacja logiki programu i obliczeń na próbkach audio	wysoka wydajność, dobra kontrola nad danymi i szerokie zastosowanie w aplikacjach audio
Framework JUCE	budowa aplikacji okienkowej, obsługa komponentów GUI, integracja z przetwarzaniem audio, FFT	popularne narzędzie do projektów audio, wygodne tworzenie interfejsu i przenośność
ImGui + Implot	budowa modularnego i skalowalnego GUI aplikacji, wyświetlanie wykresów	łatwość implementacji, wysoka jakość renderowanych wykresów (możliwość przesuwania, przybliżania)

Tabela 1. Zestawienie technologii wykorzystanych w projekcie.

Jak pokazano w tabeli 1, dobór technologii był podporządkowany prostocie implementacji aplikacji z interfejsem graficznym oraz sprawnemu wykonywaniu obliczeń na sygnale audio.

2.2 Interfejs użytkownika

Interfejs aplikacji został zaprojektowany w sposób umożliwiający szybkie przejście od wczytania pliku do obserwacji wyników. Jest on tak naprawdę zmodyfikowaną bazą z pierwszego projektu Główne elementy interfejsu obejmują:

- przycisk wyboru pliku `.wav` (File -> Load),
- obszar wyświetlania przebiegu czasowego sygnału,
- sekcję z analizą.

Sekcja z analizą audio zawiera:

- Pole typu „Dropdown” do wyboru funkcji okna

- Suwak pozwalający wybrać procent nachodzenia spektogramu
- Trzy radiobutton'y pozwalające wybrać rozmiar ramki (256,512,1024). Wybór ten stosuje się do wszystkich elementów analizy operujących na ramkach (Parametry, spektogram, cepstrum)
- Opcja normalizacji wartości parametrów
- Parametry w dziedzinie częstotliwości
- Częstotliwość tonu podstawowego wyznaczona przy użyciu cepstrum
- Dwa wykresy obok siebie - zokienkowany sygnał (Wybrany wycinek + funkcja okna) | widmo amplitudowe sygnału
- Spektogram

Rysunek 1. Główne okno aplikacji.

Rysunek 2. Główne okno aplikacji po wczytaniu audio

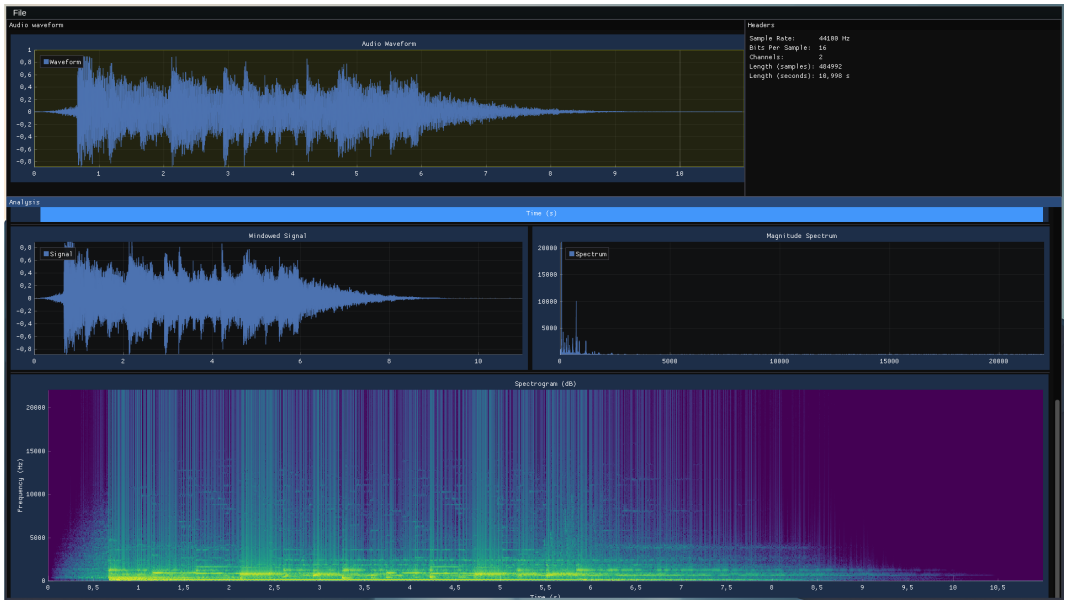

Rysunek 3. Główne okno aplikacji po wczytaniu audio - Okno, FFT i spektogram

Rysunek 3 przedstawia główny widok programu po wczytaniu pliku audio. Na tym etapie użytkownik ma dostęp do podstawowych funkcji aplikacji i wizualizacji analizowanego sygnału.

3 Opis zaimplementowanych funkcjonalności

3.1 Wczytywanie i reprezentacja sygnału

Pierwszym etapem działania programu jest odczyt danych z pliku `.wav`. Format ten przechowuje próbki sygnału audio zapisane z określoną częstotliwością próbkowania,

rozdzielczością bitową oraz liczbą kanałów. Po wczytaniu pliku dane są reprezentowane w aplikacji jako ciąg próbek amplitudy w funkcji czasu.

Przebieg czasowy sygnału jest następnie prezentowany na wykresie, oraz parametry częstotliwościowe dla każdej ramki dla okna prostokątnego i domyślnej wartości rozmiaru ramki wynoszącej 512 próbek w postaci znormalizowanej. Niżej użytkownik może znaleźć fragment zokienkowanego sygnału (obcięcie do wybranego fragmentu + funkcja okna) i widmo amplitudowe. Na samym dole dla użytkownika prezentowany jest spektogram w postaci heatmap'y.

3.2 Analiza ramkowa

W praktyce wiele cech sygnału audio wyznacza się nie dla całego nagrania jednocześnie, lecz lokalnie, dla krótkich fragmentów nazywanych ramkami. Takie podejście wynika z faktu, że sygnał audio zwykle zmienia swoje własności w czasie. Podział na ramki pozwala opisać te zmiany bardziej szczegółowo.

3.3 Cyfrowe przetwarzanie sygnałów w dziedzinie częstotliwości

Podstawowym narzędziem analizy częstotliwościowej jest transformacja Fouriera, która pozwala na dekompozycję sygnału z dziedziny czasu na składowe harmoniczne. W systemach cyfrowych wykorzystuje się algorytm Szybkiej Transformaty Fouriera (ang. *Fast Fourier Transform* - FFT), który operuje na dyskretnych próbkach sygnału. Ze względu na to, że sygnały audio (szczególnie mowa) są sygnałami niestacjonarnymi, analizę przeprowadza się w krótkich oknach czasowych, co określa się mianem krótkoczasowej transformaty Fouriera (STFT).

3.4 Funkcje okienkowe i okienkowanie

Proces wycinania fragmentu sygnału do analizy (ramkowania) wiąże się z wystąpieniem zjawiska przecieku widma. Aby zminimalizować to niekorzystne zjawisko, na każdą ramkę nakłada się funkcję okna. W projekcie zaimplementowano standardowe okna, takie jak prostokątne, trójkątne, Hamminga, Hanna oraz Blackmana. Jako rozwiązanie ponadstandardowe wybrano okno Nuttalla, które charakteryzuje się bardzo niskim poziomem listków bocznych, co pozwala na precyzyjną analizę sygnałów o szerokim zakresie dynamiki.

Okno Prostokątne (Rectangular)

Najprostsza forma okna, która w praktyce oznacza brak modyfikacji sygnału wewnątrz ramki. Charakteryzuje się najwęższym listkiem głównym, ale bardzo wysokimi listkami bocznymi.

$$w[n] = 1 \tag{1}$$

Okno Trójkątne (Bartlett)

$$w[n] = 1 - \left| \frac{n - \frac{N-1}{2}}{\frac{N-1}{2}} \right| \tag{2}$$

Okno Hanna (Hann / van Hann)

Okno typu "podniesiony cosinus". Zapewnia dobry kompromis między szerokością listka głównego a tłumieniem listków bocznych.

$$w[n] = \sin^2\left(\frac{\pi n}{N-1}\right) = 0.5\left(1 - \cos\left(\frac{2\pi n}{N-1}\right)\right) \tag{3}$$

Okno Hamminga

Zoptymalizowana wersja okna Hanna, minimalizująca poziom najwyższego listka bocznego.

$$w[n] = 0.54 - 0.46\cos\left(\frac{2\pi n}{N-1}\right) \tag{4}$$

Okno Blackmana

Okno o wyższym tłumieniu listków bocznych kosztem poszerzenia listka głównego.

$$w[n] = a_0 - a_1\cos\left(\frac{2\pi n}{N-1}\right) + a_2\cos\left(\frac{4\pi n}{N-1}\right) \tag{5}$$

Typowe wartości współczynników: $a_0 = 0.42, a_1 = 0.5, a_2 = 0.08$.

Okno Nuttalla

Wybrana jako funkcja dodatkowa, charakteryzuje się ekstremalnie niskim poziomem listków bocznych, co jest kluczowe przy analizie sygnałów o bardzo dużej dynamice. Jest to okno klasy *minimum 4-term Blackman-Harris*.

$$w[n] = a_0 - a_1\cos\left(\frac{2\pi n}{N-1}\right) + a_2\cos\left(\frac{4\pi n}{N-1}\right) - a_3\cos\left(\frac{6\pi n}{N-1}\right) \tag{6}$$

Współczynniki dla okna Nuttalla:

- $a_0 = 0.355768$
- $a_1 = 0.487396$
- $a_2 = 0.144232$
- $a_3 = 0.012604$

3.5 Parametry widmowe sygnału (Frame-Level Features)

Analiza częstotliwościowa pozwala na wyznaczenie szeregu deskryptorów opisujących charakterystykę brzmieniową sygnału:

- **Głośność (Volume):** Definiowana jako średnia energia widma w danej ramce n:

$$Vol(n) = \frac{1}{N} \sum_{k=0}^{N-1} S_n^2(k) \tag{7}$$

  gdzie S_n to dyskretne widmo, a N to rozmiar okna.

- **Środek ciężkości widma (Frequency Centroid - FC):** Określa „punkt równowagi" rozkładu mocy widmowej i jest silnie skorelowany z subiektywnym odczuciem jasności dźwięku.

$$FC(n) = \frac{\int_0^\infty \omega S_n(\omega) d\omega}{\int_0^\infty S_n(\omega) d\omega} \tag{8}$$

  Parametr ten pozwala na skuteczne rozróżnianie mowy od muzyki oraz głosek dźwięcznych od bezdźwięcznych.

- **Efektywne pasmo (Effective Bandwidth - BW):** Reprezentuje odchylenie standardowe gęstości widmowej mocy względem środka ciężkości.

$$BW^2(n) = \frac{\int_0^\infty (\omega - FC(n))^2 S_n^2(\omega) d\omega}{\int_0^\infty S_n^2(\omega) d\omega} \tag{9}$$

- **Miara płaskości widma (Spectral Flatness Measure - SFM):** Stosunek średniej geometrycznej do średniej arytmetycznej widma mocy. Wartości bliskie 1 wskazują na sygnał zbliżony do szumu białego, natomiast wartości niskie sugerują obecność wyraźnych składowych tonalnych.

- **Spectral Crest Factor (SCF):** Stosunek maksymalnej wartości mocy do średniej mocy w danym paśmie częstotliwości.

3.6 Analiza cepstralna i ton podstawowy F_0

Cepstrum, zdefiniowane w 1963 r., jest wynikiem operacji logarytmowania widma amplitudowego, a następnie poddania go odwrotnej transformacie Fouriera.

$$C(\tau) = F^{-1}(\log |F(s(t))|) \tag{10}$$

Rezultat tej operacji przedstawiany jest w dziedzinie pseudoczasu (tzw. *quefrency*). W przypadku sygnałów periodycznych (jak głoski dźwięczne), w cepstrum pojawia się wyraźne maksimum lokalne, którego położenie τ_{max} odpowiada okresowi drgań fałdów głosowych. Częstotliwość tonu podstawowego (krtaniowego) wyznacza się z zależności:

$$f_0 = \frac{1}{\tau_{max}} \tag{11}$$

Analizę tę przeprowadza się zazwyczaj w zakresie od 50 Hz do 400 Hz, co odpowiada fizjologicznym uwarunkowaniom ludzkiej krtani.

3.7 Spektrogram

Spektrogram jest trójwymiarową reprezentacją sygnału, przedstawiającą gęstość widmową mocy w funkcji czasu i częstotliwości. Pozwala on na wizualną identyfikację formantów (rezonansów traktu głosowego), które są kluczowe przy rozróżnianiu samogłosek.

Definiuje się go jako kwadrat modułu Krótkoczasowej Transformaty Fouriera (STFT). Matematycznie STFT dla sygnału dyskretnego $x[n]$ wyraża się wzorem:

$$X(m,k) = \sum_{n=0}^{N-1} x[n+mH] \cdot w[n] \cdot e^{-j\frac{2\pi}{N}kn} \tag{12}$$

gdzie:

- m – indeks ramki czasowej,
- k – indeks prążka częstotliwości,
- $w[n]$ – funkcja okna o długości N,
- H – krok analizy (hop size), definiujący przesunięcie okna.

Spektrogram $P(m,k)$ obliczany jest jako:

$$P(m,k) = |X(m,k)|^2 \tag{13}$$

Wizualizacja w skali decybelowej (dB)

Surowe dane uzyskane z algorytmu FFT reprezentują amplitudę liniową. Ze względu na fakt, że ludzki system słuchowy wykazuje czułość logarytmiczną, a zakresy dynamiczne sygnałów audio mogą obejmować wiele rzędów wielkości, zaimplementowano przeliczanie wartości widma na skalę decybelową.

Matematyczna konwersja na dB

Dla każdego prążka częstotliwości (bin) o amplitudzie $|X(m,k)|$, wartość w decybelach obliczana jest zgodnie ze wzorem:

$$L_{dB}(m,k) = 20 \cdot \log_{10}\left(\frac{|X(m,k)| + \epsilon}{A_{ref}}\right) \tag{14}$$

gdzie:

- ϵ – stała stabilizująca (np. 10^{-12}), zapobiegająca obliczaniu logarytmu z zera w przypadku absolutnej ciszy,
- A_{ref} – wartość referencyjna amplitudy.

Normalizacja i zakres dynamiczny

W aplikacji zastosowano technikę normalizacji do poziomu szczytowego (ang. *peak normalization*). Oznacza to, że najgłośniejszy element w całym analizowanym sygnale przyjmuje wartość 0 dB, a wszystkie pozostałe składowe mają wartości ujemne:

$$L_{norm}(m,k) = L_{dB}(m,k) - \max(L_{dB}) \tag{15}$$

Aby zapewnić czytelność wykresu i wyeliminować szum tła o niskiej amplitudzie, wprowadzono progowanie (ang. *clamping*). Wyniki są przycinane do określonego zakresu dynamicznego (np. od -80 dB do 0 dB). Wartości poniżej tego progu są traktowane jako tło, co pozwala na wyraźną wizualizację formantów oraz struktury harmonicznej sygnału, które w skali liniowej byłyby niemal niewidoczne.

Zalety prezentacji w dB

Zastosowanie skali decybelowej w spektrogramie pozwala na:

- jednoczesną obserwację bardzo głośnych składowych (np. tonu podstawowego) oraz cichych detali (wyższe harmoniczne, szumy tarcia),
- lepsze dopasowanie wizualizacji do subiektywnego odczucia głośności przez człowieka,
- łatwiejszą identyfikację formantów samogłosek, które są kluczowe dla analizy fonetycznej sygnału mowy.

4 Przeprowadzone eksperymenty

4.1 Porównanie parametrów dla różnych głosów

Zdecydowano porównać wartości wszystkich parametrów na poziomie ramki w dziedzinie częstotliwości dla różnych słów róznych głosów spośród przygotowanych wcześniej nagrań. Wybrano dwa głosy żeńskie i dwa głosy męskie. Zestaw słów, który przetestowano, to: „Zero”, „Zid”, „Dziabba’, „Chrząszcz”, „Dum”, „Komatyn”, co łącznie dało 24 wykresy do analizy porównawczej zachowania się różnych parametrów

Ogólne obserwacje na przestrzeni próbek

Zauważono, iż dla różnych osób zachowania parametrów są bardzo różne i nie ma jednego unikalnego wzoru. Na Rysunku 4 pokazano przykładowy wynik porównania słowa „Chrząszcz” dla jednego głosu męskiego i żeńskiego.

Widać tu przykładowo, że początek "Chrz-"u drugiej osoby generuje bardzo niskie wartości parametrów, a u pierwszej od samego początku widać fluktuacje o wysokich wartościach. Podobne różnice zaobserwowano również dla spółgłoski „m” - z analogicznym rezultatem (jedna osoba - niskie wartości, druga - wysokie i wyraźne na tle innych).

Rysunek 4. Porównanie parametrów dwóch różnych głosów dla słowa „Chrząszcz”

Rysunek 5. Parametry słowa „Dziabba” dla różnych osób.

Jeśli chodzi o rozróżnianie głosu męskiego/żeńskiego to zauważono, iż zazwyczaj parametry dla głosu żeńskiego osiągają większe wartości, niż te dla głosów męskich (w szczególności dla spółgłosek dźwięcznych, na Rysunku 4 widać przykładowo że głoski „sz” i „cz” na końcu osiągają wyższe wartości dla głosu męskiego).

Środek ciężkości widma

Nietrudno było zauważyć na przestrzeni nagrań, iż przeważnei samogłoski mają bardzo niską wartość FC. Na Rysunku 5 przedstawiono przykładowe wyniki dla słowa „Dziabba”.

Zaburzyło to trochę postawioną hipotezę, gdyż dla samogłoski „i” parametr centroidu był wyraźnie wysoki na tle innych. Uznano, iż FC całkiem dobrze reprezentuje „jasność” dźwięku. Dla takich głosek jak np. „i” widać jego wysokie wartości, a przykładowo dla „u” czy „a” są one zdecydowanie niższe. Na Rysunku 6 przedstawiono również wyniki dla logotomu „dum”

Widać wyraźnie gwałtowny spadek dla głosku „u” przy wyższych wartościach dla „d” i

23_f

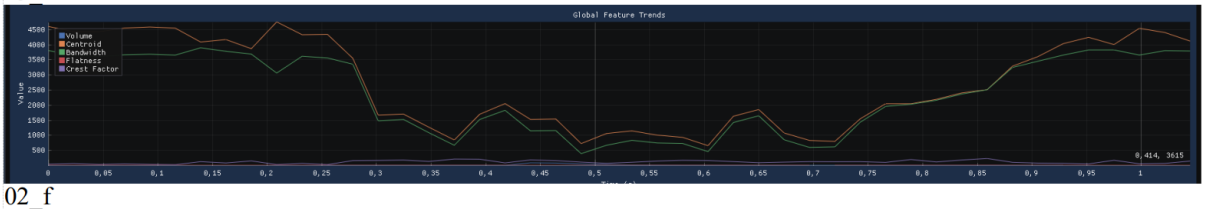

02_f

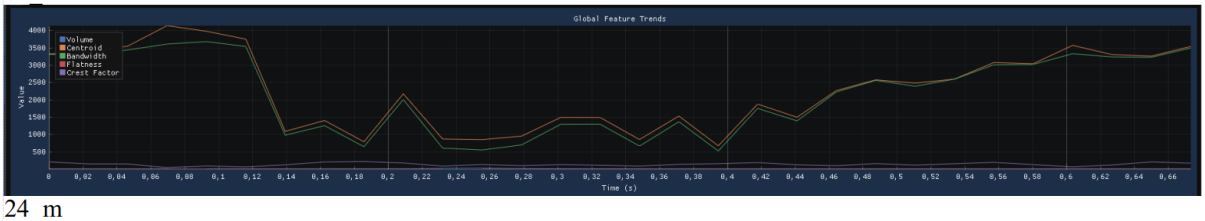

24_m

Rysunek 6. Parametry słowa „dum” dla różnych osób

„m”.

Warto się również odwołać do Rysunku 4. Wyniki ukazują (wyraźny lub lekki w przypadku drugiego speaker'a) spadek centroidu przy głosce „ą” oraz wysokie wartości dla głosek szumiących (które w sumie po części można uznać za „jasne” w kontraście do ciemnego „a”).

Efektywne pasmo

Dla pasma poczyniono podobne obserwacje, co dla FC (co widać na poprzednio przytoczonych rysunkach, gdzie linie przebiegają bardzo podobnie). Również dla samogłosek jest ono zazwyczaj wąskie, a dla spółgłosek szumiących - szerokie. Wyjątkiem znów jest samogłoska „i” (zjawisko to będzie wyjaśnione w dalszych sekcjach przy opisie analizy formantów).

Miara płaskości widma

Wartości płaskości widma dla wszystkich badanych słów były niemal równe 0. Świadczy to o tonalnym/melodycznym charakterze rozważanych nagrań. Jest spodzieawne, że wartości bliskie 1 są charakterystyczne dla szumu białego, ukazanego na Rysunku 7 porównawczo z białym szumem.

Na tym zestawieniu widać idealnie też kiedy jest mówione słowo, a kiedy następuje po nim cisza (lekki szum biały), kiedy to po skończonej mowie płaskość widma skacze do góry.

Postanowiono zbadać, czy może głoski szumiące nie dadzą wzrostu płaskości widma („szcz”), gdyż w swojej strukturze są one bardzo podobne do białego szumu. Wyniki przedstawia Rysunek .

Przypuszczenia się potwierdziły - spółgłoski bezdźwięczne syczące dają znaczy wzrost

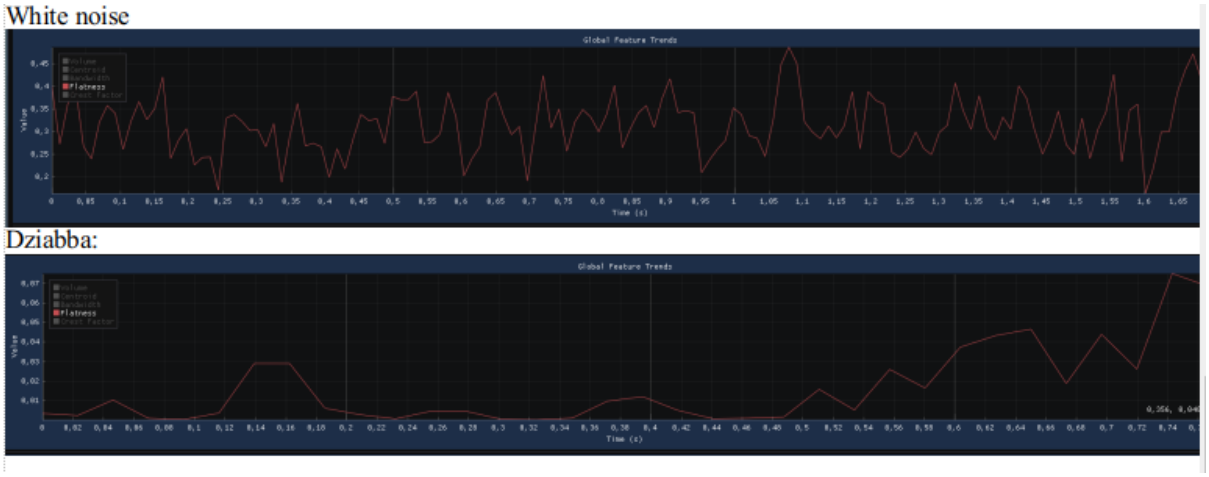

Rysunek 7. Zestawienie płaskości widma dla słowa „Dziabba' z wynikami dla białego szumu

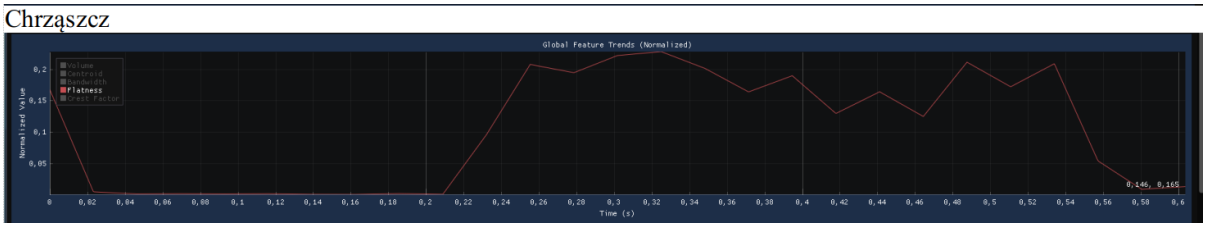

Rysunek 8. Parametr płaskości widma dla słowa „Chrząszcz"

płaskości widma, co jest jednoznaczne z tym, że zawierają dużo składowych i nie mają jednej, dominującej częstotliwości podstawowej.

Spektralny współczynnik szczytu

Dla SCF zauważono ciekawe rozróżnienie wyników dla głosek dźwięcznych i bezdźwięcznych. Na Rysunku 9 przedstawiono zestawienie tego parametru dla słów „Dziabba" oraz „Chrząszcz".

Dla słów składających się z samych głosek dźwięcznych, Crest Factor ma relatywnie wysokie wartości, zaś dla spółgłosek bezdźwięcznych (przytoczony „Chrząszcz") wyraźnie widać peak dla głoski „ą" oraz niskie wartości dla „sz" oraz „cz" (z dokładnością do wybuchowości tej ostatniej).

4.2 Formanty

Rola formantów w rozpoznawaniu głosek

Dla zrozumienia mowy kluczowe są dwa pierwsze formanty, oznaczane jako F_1 i F_2:

- **Formant F_1:** Jest ściśle powiązany ze stopniem rozwarcia szczęki (wysokością języka). Niskie wartości F_1 odpowiadają samogłoskom przymkniętym (np. „i", „u"), natomiast wysokie samogłoskom otwartym (np. „a").
- **Formant F_2:** Odpowiada za miejsce artykulacji (przód/tył jamy ustnej). Przykładowo, samogłoska „i" charakteryzuje się bardzo wysoką wartością F_2, co odróżnia

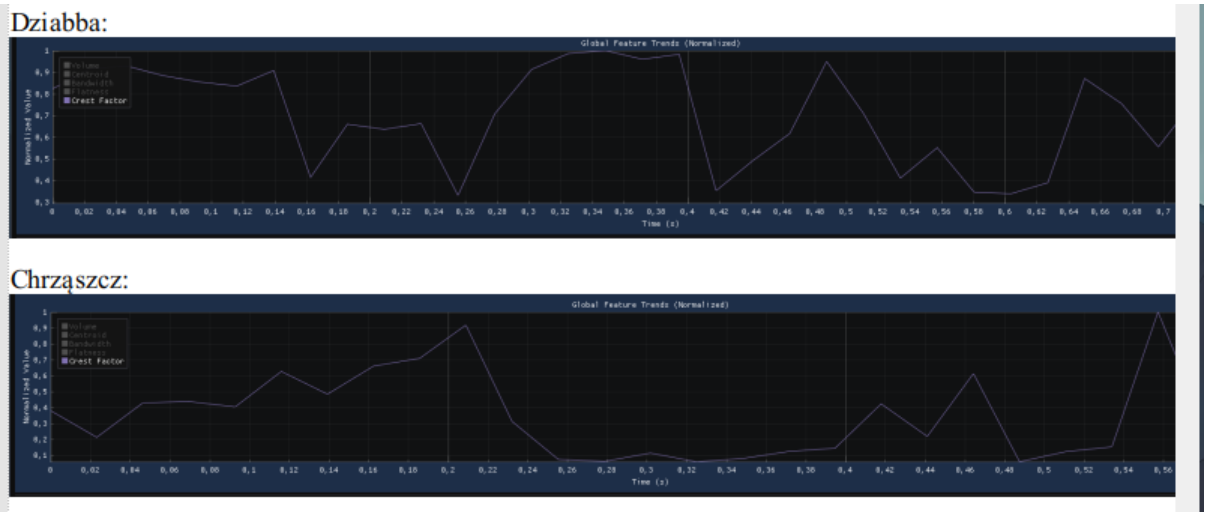

Rysunek 9. Parametr Spektralnego Współczynnika Szczytu dla słów „Dziabba” oraz „Chrząszcz” dla jednego speakera, znormalizowane

ją od samogłoski „u”, mimo podobnych wartości F_1.

Zmienność formantów

Wartości formantów nie są stałe i podlegają istotnym fluktuacjom w zależności od kontekstu fonetycznego oraz cech osobniczych lektora:

- **Różnice międzyosobnicze:** Ze względu na różnice w budowie anatomicznej traktu głosowego (długość i objętość), te same fonemy realizowane przez różne osoby będą posiadały formanty o nieco innych wartościach częstotliwości.
- **Różnice w realizacjach:** Formanty mogą różnić się nawet u tej samej osoby w zależności od tempa mowy, akcentu czy emocji towarzyszących wypowiedzi.
- **Identyfikacja lektora:** Wyższe formanty (F_3, F_4) niosą mniej informacji o samej głosce, a więcej o indywidualnych cechach anatomicznych i barwie głosu konkretnego mówcy.

Wartości formantów różnych samogłosek

Najpierw znaleziono tablicowe wartości formantów z różnych badań w internecie, wyniki przedstawia Tabela 2

Wybór okna Hamminga do analizy formantów

Do szczegółowej analizy widmowej samogłosek i wyznaczania częstotliwości formantów zdecydowano się na wykorzystanie okna Hamminga. Wybór ten jest podyktowany faktem, iż okno to stanowi optymalny kompromis pomiędzy szerokością listka głównego a poziomem listków bocznych w analizie sygnałów mowy.

W procesie identyfikacji formantów kluczowe jest zachowanie odpowiedniej rozdzielczości częstotliwościowej, aby blisko położone rezonanse (szczególnie F_1 i F_2 w samogłoskach

	Łobacz (1996)		Gonet (1993)		Kleśta (1998)			
Samogłoska	dzieci		dorośli		kobiety		mężczyźni	
	F1	F2	F1	F2	F1	F2	F1	F2
i	388	3109	269	2287	361	2752	282	2096
j	469	2426	380	1799	484	2077	388	1742
e	684	2467	494	1807	599	2140	474	1750
a	1112	2018	721	1406	821	1627	620	1315
o	664	1518	518	1075	619	1194	491	1025
u	481	1263	345	899	418	963	354	918

Tabela 2. Wartości częstotliwości formantów różncyh samogłosek, https://www.komlogo.pl/encyklopedia/119-f/691-formanty-dzwiekow

takich jak „u” czy „o”) nie uległy zjawisku zlania się w jeden wierzchołek. Okno Hamminga zapewnia wystarczająco wąski listek główny, by utrzymać tę separację, a jednocześnie oferuje znaczne tłumienie listków bocznych (przecieku widma) w porównaniu do okna prostokątnego. Dzięki temu doliny między formantami są wyraźne, a obwiednia widma pozostaje czytelna, co umożliwia precyzyjne odczytanie wartości rezonansowych traktu głosowego. Ze względu na te właściwości, okno Hamminga jest uznawane za standard w cyfrowym przetwarzaniu sygnałów fonetycznych.

Formanty w „a”

Najpierw przebadano formanty w samogłosce „a”. Na podstawie Tabeli 2 spodziewano się wartości $F_1 = 600 - 700$, $F_2 = 1300 - 1400$. Wyniki analizy dla różnych słów dla jednego speakera przedstawia Rysunek 10.

Uzyskano wynik $F_1 \approx 690$ oraz $F_2 \approx 1000 - 1200$. Na podstawie widma ciężko było określić wartość drugiego formantu, gdyż widać, że pomiędzy różnymi wystąpieniami samogłoski największe różnice są właśnie w tych dalszych składowych. Ogólna struktura widma wydaje się być podobna, pierwszy formant jest napewno najbardziej widoczny i „stacjonarny” na przestrzeni różnych wystąpień w słowach.

Wartości te zgadzają się z tablicowymi oprócz drugiego formantu, który wyszedł nieco niższy.

Formanty w „i”

Kolejno zbadano formanty w samogłosce „i”. Spodziewane wyniki tablicowe to $F_1 = 250 - 300$ oraz $F_2 = 2000 - 2300$. Wyniki przedstawia Rysunek 11.

Zaobserwowano tutaj dużą zmienność widm na przestrzeni różnych wystąpień tej samogłoski. Na podstawie analzy widma można wywnioskować, że pierwszy formant $F_1 \approx 250 - 300$, a drugi $F_2 \approx 2100$, co tym razem zgadza się z wynikami tablicowymi.

Teraz możliwa jest również odpowiedź na pytanie postawione wcześniej przy analizie FC i szerokości pasma samogłoski „i” - widać, iż drugi formant jest bardzo daleko w porównaniu do pierwszego. Daje to nam właśnie bardzo duże wartości tych dwóch parametrów.

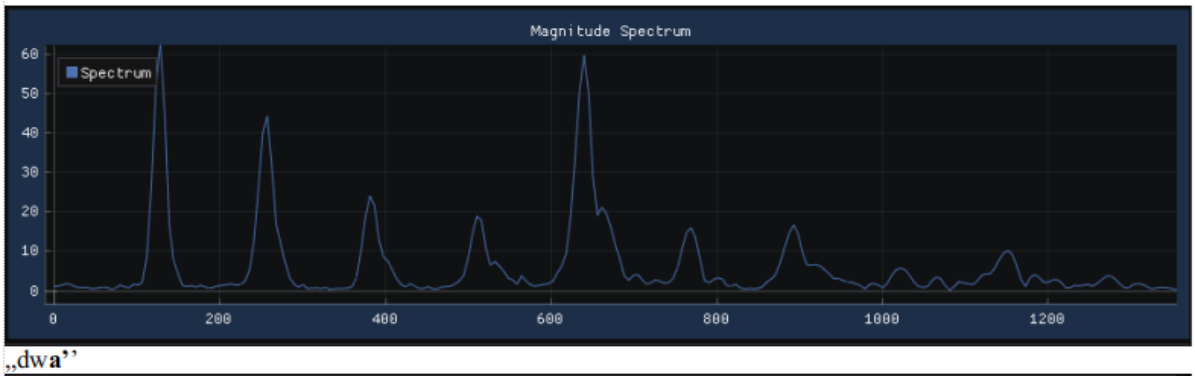

„dwa''

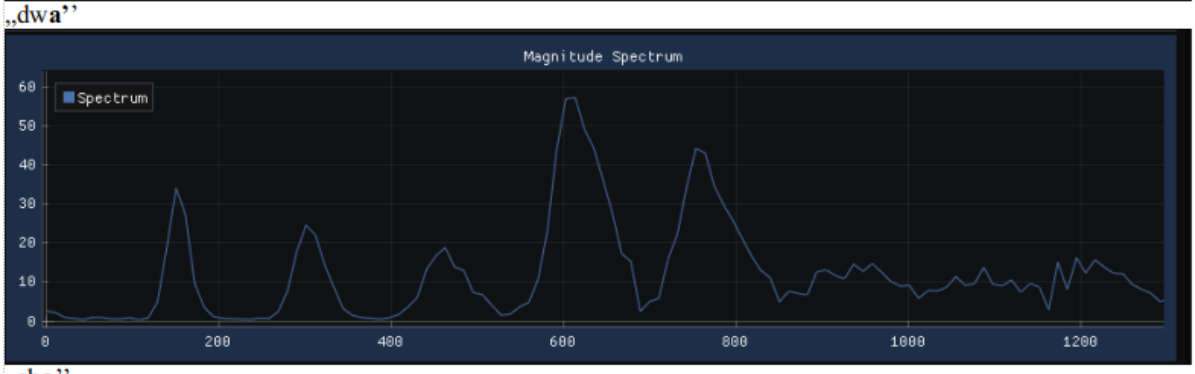

„aba''

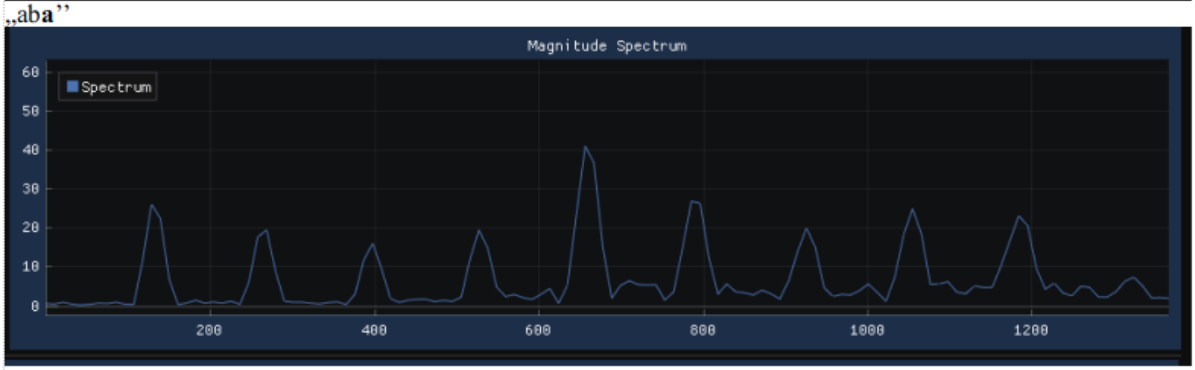

„abe''

Rysunek 10. Widmo amplitudowe dla różnych wystąpień samogłoski „a”

„Pięć''

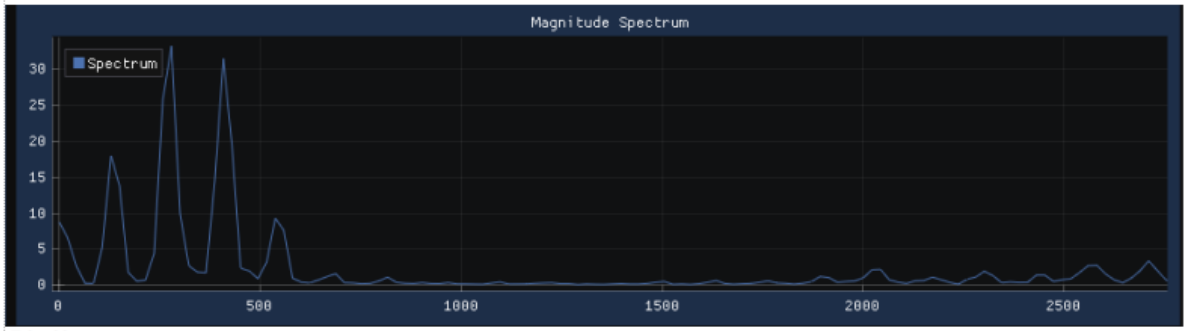

„Pies''

„ugi''

Rysunek 11. Widmo amplitudowe dla różnych wystąpień samogłoski „i"

Rysunek 12. Widmo amplitudowe dla różnych wystąpień samogłoski „o”

Formanty w „o”

Następnie zbadano formanty w samogłosce „o”. Spodziewano się wartości $F_1 = 500$ oraz $F_2 = 1000$. Wyniki przedstawia Rysunek 12.

Dla tego speaker'a na podstawie widm można oszacować $F_1 \approx 500$, a $F_2 \approx 850 - 950$. Są to (z drobnym błędem) wartości bliske tablicowych dla tej samogłoski. Znów zauważono zróżnicowanie wartości formantu drugiego i innych składowych występujących po F_1 dla różnych wystąpień samogłoski.

Formanty w „u”

Ostatnią przebadaną samogłoską była „u”. Z tablic można odczytać jej spodziewane wartości wynoszące $F_1 = 350$ oraz $F_2 = 900$. Wyniki przedstawia Rysunek 13.

Na podstawie widma amplitudowego można wywnioskować wartości $F_1 \approx 400$ oraz $F_2 \approx 700$. Znów tym razem wartość drugiego formantu wyszła nieco inna niż średnie wyniki tablicowe. Warto zauważyć jednak, iż dla tej samogłoski widmo amplitudowe

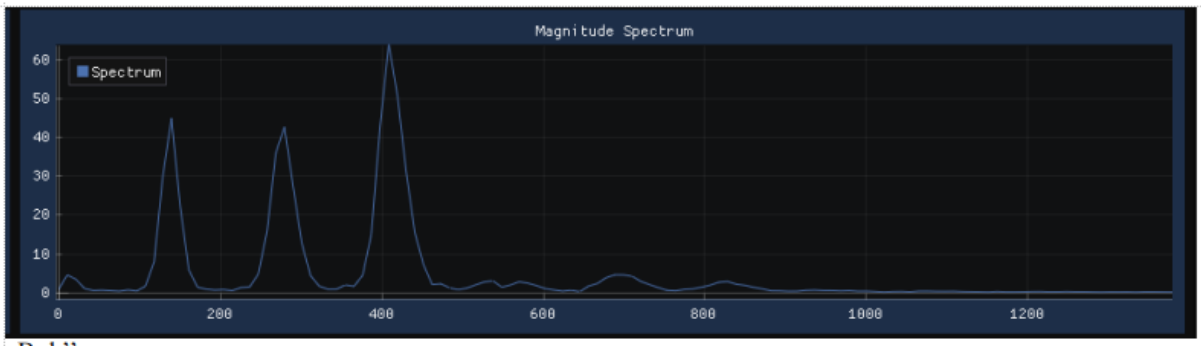

„Bub”

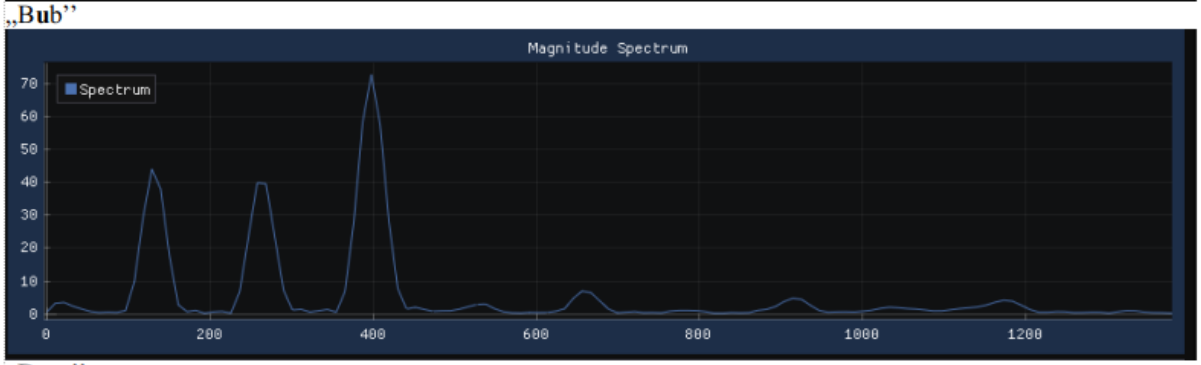

„Dum”

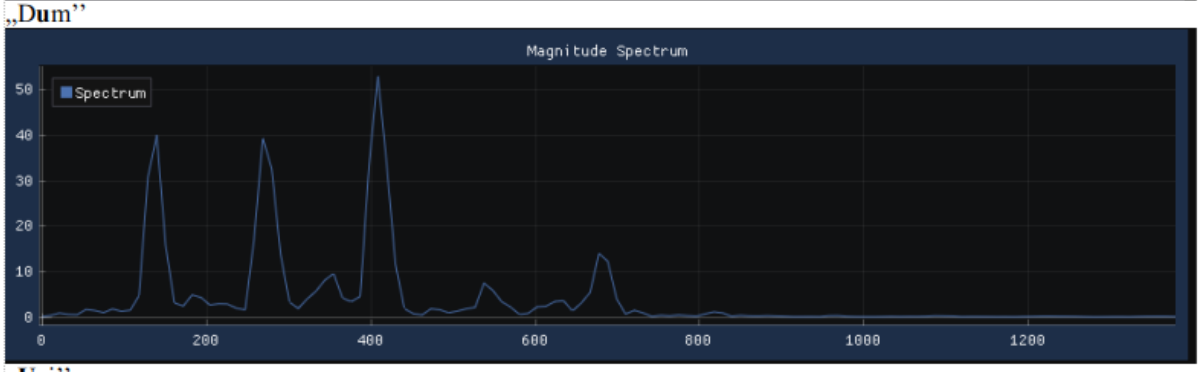

„Ugi”

Rysunek 13. Widmo amplitudowe dla różnych wystąpień samogłoski „u”

Rysunek 14. Widma amplitudowe dla tej samej samogłoski w tym samym słowie dla różnych speaker'ów

jest najbardziej stabilne pod kątem zmian na przestrzeni różnych miejsc wystąpienia samogłoski „u" (największe różnice występują po pierwszym formancie).

Formanty u różnych speakerów

Wnioskując na podstawie znacznych różnic w widmach wymawiaonych samogłosek dla jednego lektora spodziewano się również znacznych różnic pomiędzy różnymi speaker'ami. Postanowiono to sprawdzić. Okazało się, iż widma wymawianych samogłosek są bardzo różne dla różnych mówców. Każdy z nich ma trochę inne formanty, a także inny rozkład amplitud składowych harmonicznych. Przykładowe wyniki dla samogłoski „u" przedstawiono na Rysunku 14.

4.3 Zbadanie wpływu funkcji okienkowych

Celem eksperymentu było sprawdzenie, w jaki sposób wybór funkcji okienkowej wpływa na widmo częstotliwościowe analizowanego sygnału. Szczególną uwagę zwróciliśmy na zjawisko przecieku widmowego oraz możliwość rozróżnienia dwóch blisko położonych składowych częstotliwościowych.

Bliskie częstotliwości

W pierwszym eksperymencie przygotowano sygnał będący sumą dwóch sinusoid o bardzo zbliżonych częstotliwościach. Sygnał został wygenerowany w programie Audacity. Najpierw utworzono sinusoidę o częstotliwości 440 Hz, a następnie na osobnej ścieżce dodano drugą sinusoidę o częstotliwości 445 Hz. Obie składowe miały taką samą amplitudę, dzięki czemu eksperyment pozwalał skupić się głównie na rozdzielczości częstotliwościowej, a nie na różnicach poziomu sygnału.

Po wygenerowaniu obu ścieżek zostały one połączone za pomocą opcji *Mix and Render*. W rezultacie otrzymano jeden sygnał będący sumą dwóch przebiegów sinusoidalnych:

$$x(t) = A\sin(2\pi \cdot 440t) + A\sin(2\pi \cdot 445t)$$

gdzie A oznacza amplitudę obu składowych. Różnica częstotliwości wynosi jedynie 5 Hz, dlatego składowe znajdują się bardzo blisko siebie w widmie. W dziedzinie czasu można zauważyć charakterystyczne zmiany obwiedni sygnału, czyli dudnienia, wynikające z nakładania się dwóch sinusoid o podobnych częstotliwościach.

Następnie sygnał został poddany analizie częstotliwościowej z użyciem różnych funkcji okienkowych: prostokątnej, trójkątnej, Hamminga, Hanna, Blackmana oraz Nuttalla. Dla każdej funkcji okna porównano wygląd sygnału po okienkowaniu oraz odpowiadające mu widmo amplitudowe.

Na wykresach widma analizowano przede wszystkim:

- czy dwie bliskie składowe częstotliwościowe są rozróżnialne,
- jak szerokie są główne maksima widma,
- jak duży jest przeciek widmowy wokół głównych składowych,
- ile dodatkowych prążków pojawia się w sąsiedztwie właściwych częstotliwości.

Na poniższych wykresach przedstawiono widma amplitudowe tego samego sygnału złożonego z dwóch sinusoid o częstotliwościach 440 Hz oraz 445 Hz, analizowanego z użyciem różnych funkcji okienkowych. Dla każdej funkcji okna pokazano dwa wykresy: pierwszy przedstawia widmo w szerszym zakresie amplitudy, natomiast drugi pokazuje dolną część widma, gdzie lepiej widoczne są słabsze składowe oraz ewentualny przeciek widmowy.

Warto zauważyć, że główne składowe sygnału mają dużo większą amplitudę niż prążki boczne. Z tego powodu na wykresach w pełnej skali różnice między niektórymi oknami

są słabo widoczne. Różnice pojawiają się przede wszystkim przy małych wartościach amplitudy, czyli w dolnej części widma.

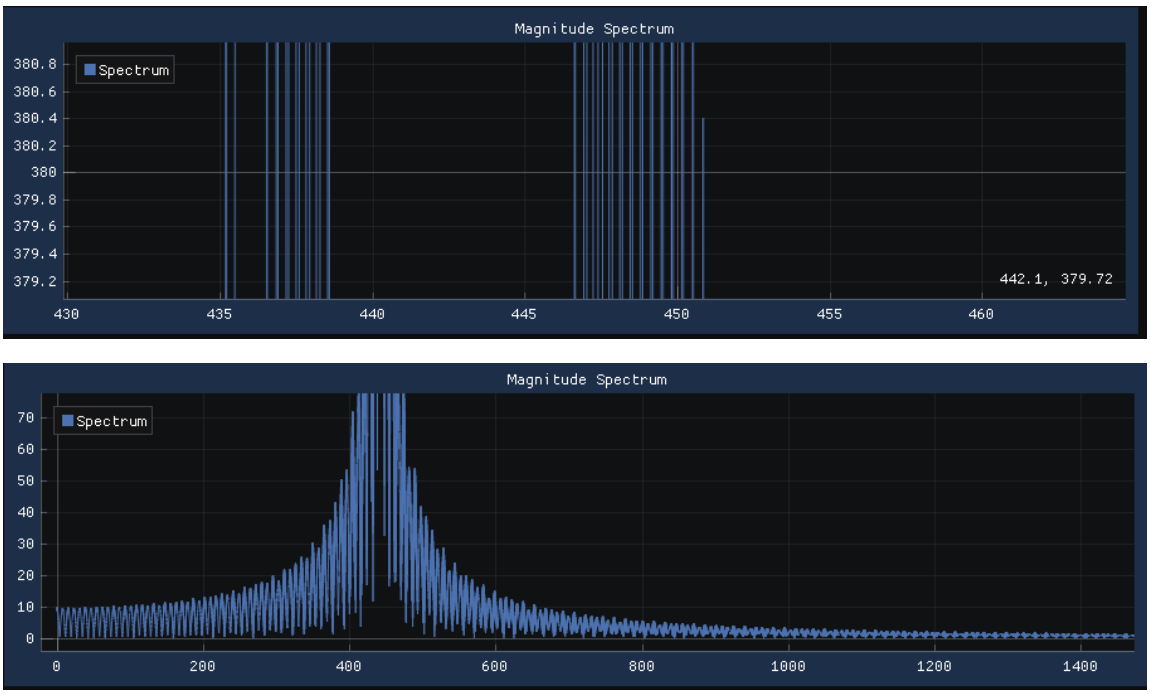

Rysunek 15. Widmo amplitudowe sygnału 440 Hz + 445 Hz dla okna prostokątnego. U góry widmo w szerszym zakresie amplitudy, na dole powiększona dolna część widma.

Dla okna prostokątnego widoczny jest największy przeciek widmowy. Na dolnym wykresie energia sygnału rozlewa się na szeroki zakres częstotliwości, a wokół głównego obszaru widma pojawia się wiele oscylacji i prążków bocznych.

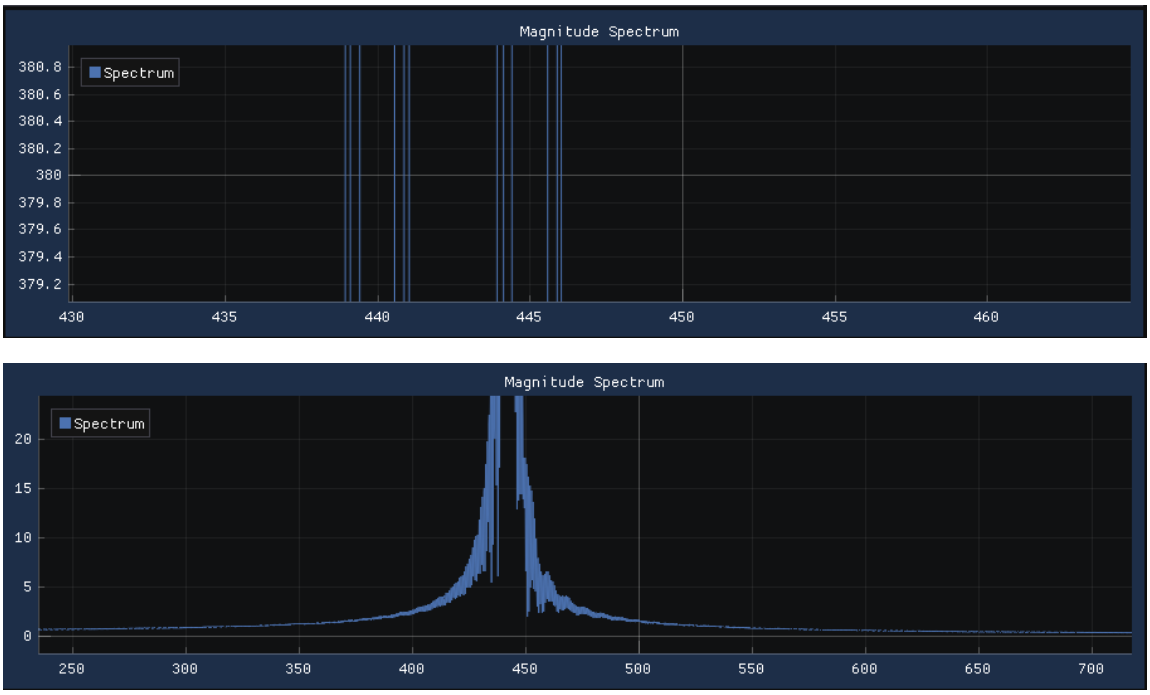

Rysunek 16. Widmo amplitudowe sygnału 440 Hz + 445 Hz dla okna trójkątnego. U góry widmo w szerszym zakresie amplitudy, na dole powiększona dolna część widma.

Dla okna trójkątnego przeciek widmowy jest mniejszy niż dla okna prostokątnego. Energia nadal rozciąga się wokół głównych częstotliwości, ale oscylacje są słabsze i mniej rozproszone.

Rysunek 17. Widmo amplitudowe sygnału 440 Hz + 445 Hz dla okna Hamminga. U góry widmo w szerszym zakresie amplitudy, na dole powiększona dolna część widma.

Dla okna Hamminga na wykresie w szerszym zakresie amplitudy widoczne są głównie prążki odpowiadające analizowanym częstotliwościom 440 Hz oraz 445 Hz. Przy większych wartościach amplitudy nie widać wyraźnych dodatkowych prążków bocznych, dlatego widmo sprawia wrażenie czystego i skupionego wokół głównych składowych.

Dopiero po powiększeniu dolnej części widma można zauważyć słabsze oscylacje oraz prążki boczne. Oznacza to, że przeciek widmowy nadal występuje, ale ma znacznie mniejszą amplitudę niż główne składowe sygnału. W porównaniu z oknem prostokątnym okno Hamminga wyraźnie ogranicza przeciek widmowy, chociaż nie eliminuje go całkowicie.

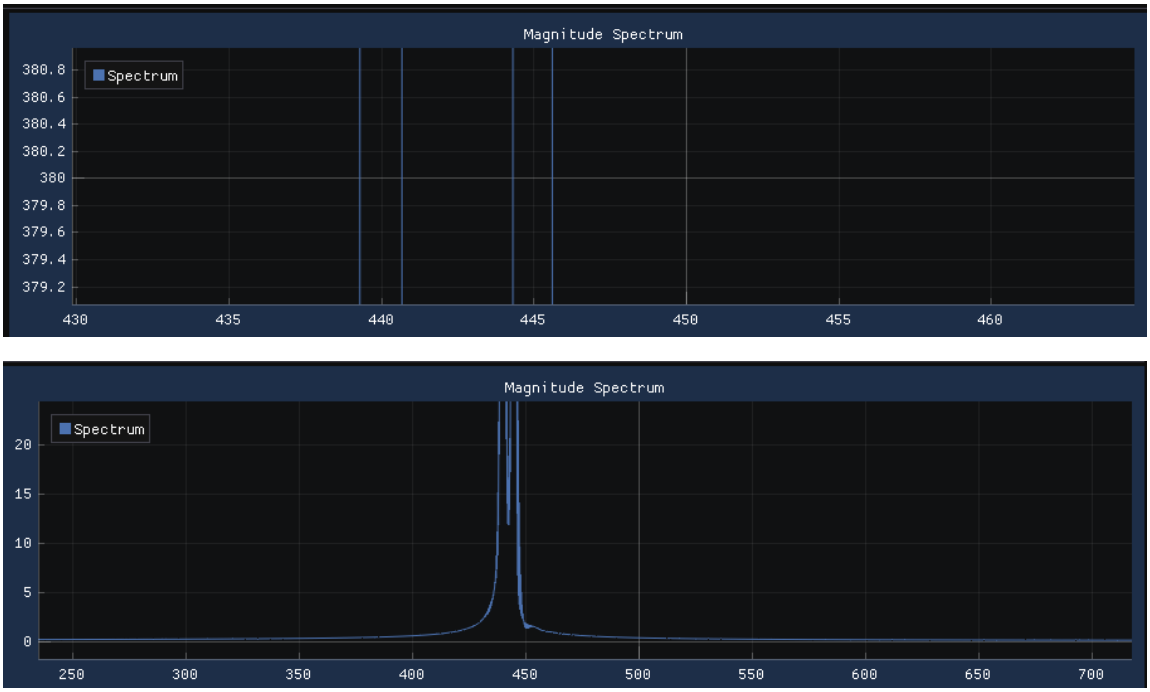

Rysunek 18. Widmo amplitudowe sygnału 440 Hz + 445 Hz dla okna Hanna. U góry widmo w szerszym zakresie amplitudy, na dole powiększona dolna część widma.

Dla okna Hanna widmo w pełnej skali wygląda podobnie jak dla okna Hamminga. Główne składowe znajdują się w okolicy częstotliwości 440 Hz i 445 Hz, natomiast różnice są widoczne głównie w dolnej części wykresu. Na dolnym wykresie przeciek poza głównym obszarem jest słabo widoczny.

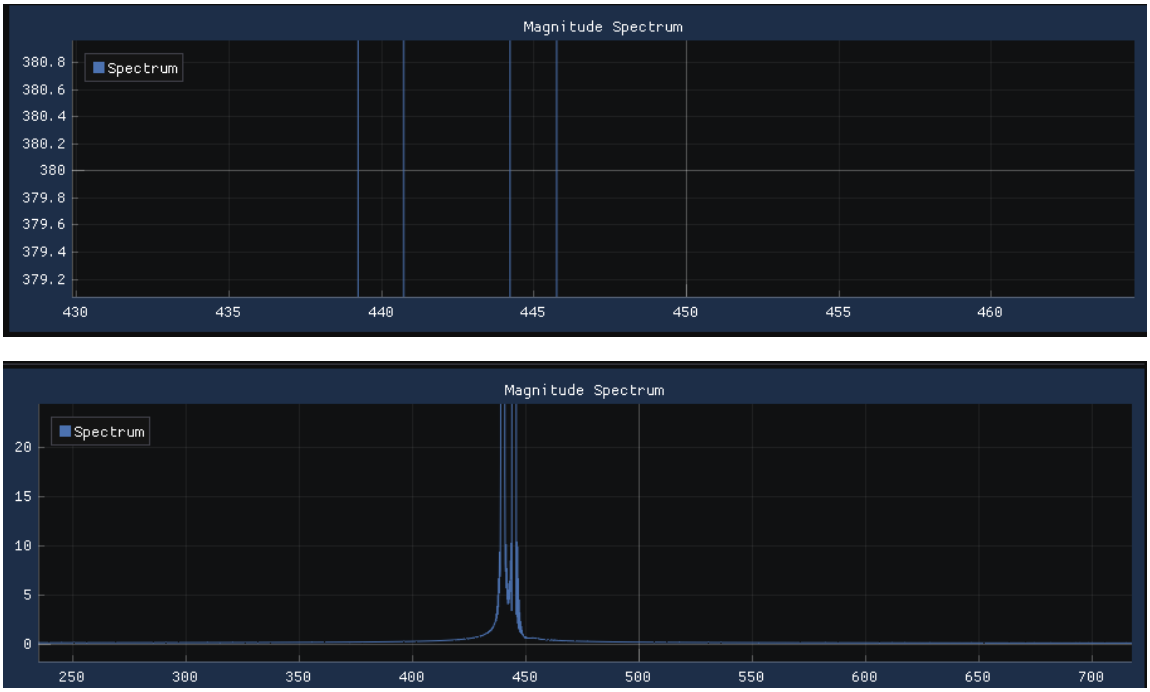

Rysunek 19. Widmo amplitudowe sygnału 440 Hz + 445 Hz dla okna Blackmana. U góry widmo w szerszym zakresie amplitudy, na dole powiększona dolna część widma.

Dla okien Hanna oraz Blackmana otrzymano bardzo podobny kształt widma. Na

wykresach w szerszym zakresie amplitudy widoczne są głównie prążki odpowiadające częstotliwościom 440 Hz oraz 445 Hz. Po powiększeniu dolnej części widma widać jednak niewielkie rozlanie energii wokół głównych składowych. Objawia się ono jako łagodnie opadający fragment widma po obu stronach głównego maksimum.

W analizowanym przykładzie różnice między oknem Hanna i Blackmana nie są bardzo wyraźne na podstawie otrzymanych wykresów. Można jednak zauważyć, że oba okna skutecznie ograniczyły widoczny przeciek widmowy w porównaniu z oknem prostokątnym i oknem Hamminga. Przeciek nie został całkowicie usunięty, ale jego amplituda jest znacznie mniejsza i widoczna głównie dopiero po powiększeniu dolnej części widma.

Rysunek 20. Widmo amplitudowe sygnału 440 Hz + 445 Hz dla okna Nuttalla. U góry widmo w szerszym zakresie amplitudy, na dole powiększona dolna część widma.

Dla okna Nuttalla otrzymano najczystsze widmo spośród analizowanych funkcji okienkowych. Zarówno na wykresie w szerszym zakresie amplitudy, jak i po powiększeniu dolnej części widma, energia jest skupiona praktycznie wyłącznie w pobliżu głównych składowych odpowiadających częstotliwościom 440 Hz oraz 445 Hz.

W dolnej części wykresu nie widać wyraźnego rozmycia widma ani zauważalnych prążków bocznych oddalonych od głównych częstotliwości. Oznacza to, że w tym przypadku okno Nuttalla bardzo skutecznie ograniczyło widoczny przeciek widmowy. W porównaniu z oknem prostokątnym, trójkątnym oraz Hamminga wynik jest znacznie bardziej czytelny, a nawet w porównaniu z oknami Hanna i Blackmana widmo wygląda ostrzej w dolnym zakresie amplitudy.

Różne amplitudy

W drugim eksperymencie przygotowano sygnał będący sumą dwóch sinusoid o różnych amplitudach. Celem eksperymentu było sprawdzenie, czy słabsza składowa częstotliwościowa pozostaje widoczna w obecności silniejszej składowej oraz jak wybór funkcji okienkowej

wpływa na jej zauważalność w widmie.

Sygnał został wygenerowany w programie Audacity. Najpierw utworzono sinusoidę o częstotliwości 440 Hz i amplitudzie 0,5, a następnie na osobnej ścieżce dodano drugą sinusoidę o częstotliwości 470 Hz i amplitudzie 0,05. Po wygenerowaniu obu ścieżek zostały one połączone za pomocą opcji *Mix and Render*. Otrzymany sygnał można zapisać jako:

$$x(t) = 0{,}5\sin(2\pi \cdot 440t) + 0{,}05\sin(2\pi \cdot 470t)$$

W tym przypadku jedna składowa ma dziesięciokrotnie większą amplitudę od drugiej. Eksperyment pozwala więc sprawdzić, czy słabszy składnik widma nie zostaje zamaskowany przez przeciek widmowy pochodzący od silniejszej składowej.

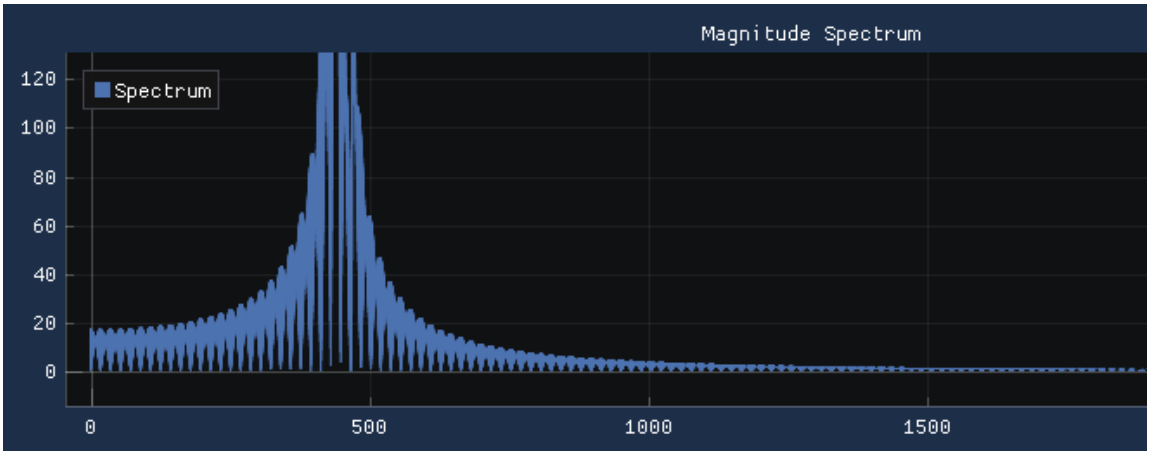

Rysunek 21. Widmo amplitudowe sygnału 440 Hz, $A = 0{,}5$ oraz 470 Hz, $A = 0{,}05$ dla okna prostokątnego.

Dla okna prostokątnego widoczny jest silny pik w okolicy częstotliwości 440 Hz. Energia tej składowej rozlewa się jednak na szeroki zakres częstotliwości, co objawia się licznymi oscylacjami i prążkami bocznymi. Słabsza składowa o częstotliwości 470 Hz nie jest widoczna jako osobny, wyraźny pik, ponieważ znajduje się w obszarze przecieku widmowego pochodzącego od silniejszego tonu. Pokazuje to, że dla okna prostokątnego słabsza składowa może zostać częściowo zamaskowana przez silniejszą.

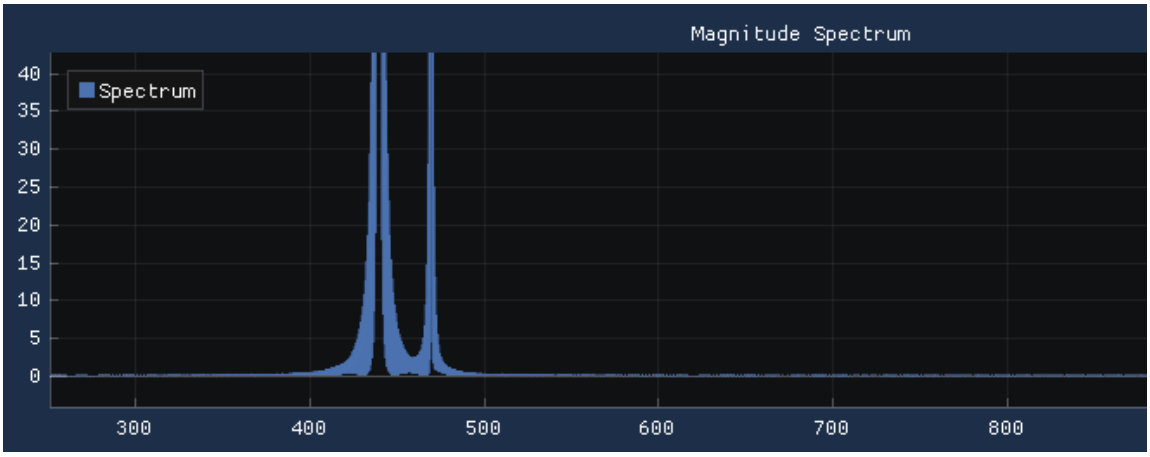

Rysunek 22. Widmo amplitudowe sygnału 440 Hz, $A = 0{,}5$ oraz 470 Hz, $A = 0{,}05$ dla okna trójkątnego.

Dla okna trójkątnego widmo jest znacznie mniej rozproszone niż dla okna prostokątnego. Energia silniejszej składowej jest bardziej skupiona w pobliżu głównego piku, a prążki boczne mają mniejszą amplitudę. Dzięki temu słabsza składowa o częstotliwości 470 Hz jest już wyraźnie widoczna obok silniejszej składowej 440 Hz. Wciąż można jednak zauważyć pewne oscylacje boczne wokół głównych częstotliwości.

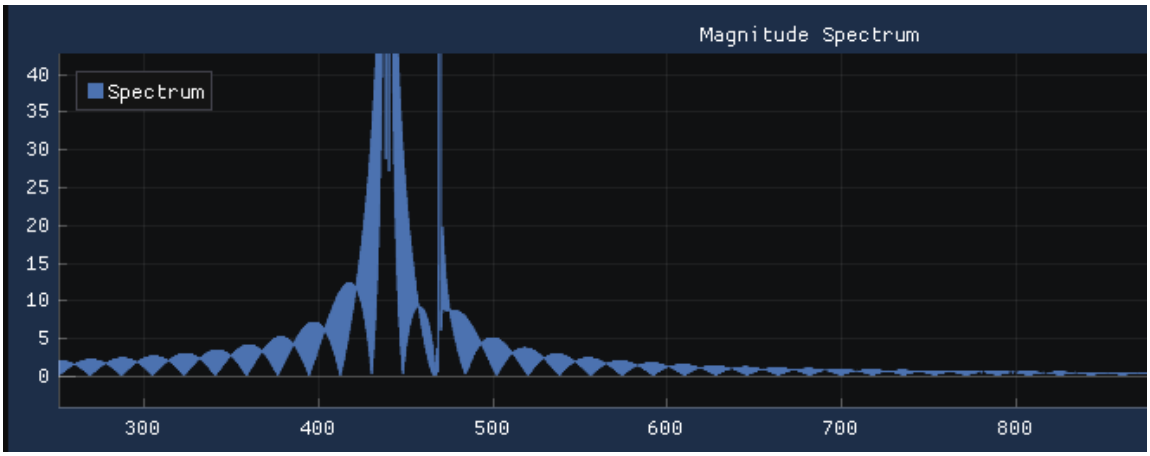

Rysunek 23. Widmo amplitudowe sygnału 440 Hz, $A = 0{,}5$ oraz 470 Hz, $A = 0{,}05$ dla okna Hamminga.

Dla okna Hamminga przeciek widmowy jest znacznie bardziej ograniczony niż w przypadku okna prostokątnego. Główna składowa pozostaje widoczna w okolicy 440 Hz, natomiast słabszy składnik w pobliżu 470 Hz jest łatwiejszy do odróżnienia od tła widma.

Wynik dla okna Hamminga jest bliższy wynikowi uzyskanemu dla okna trójkątnego niż dla okna prostokątnego. W obu przypadkach widmo jest skupione głównie w pobliżu analizowanych częstotliwości, a słabsza składowa jest widoczna obok silniejszej. Dla okna Hamminga nadal występują jednak boczne oscylacje wokół głównych składowych, dlatego przeciek widmowy nie został całkowicie usunięty.

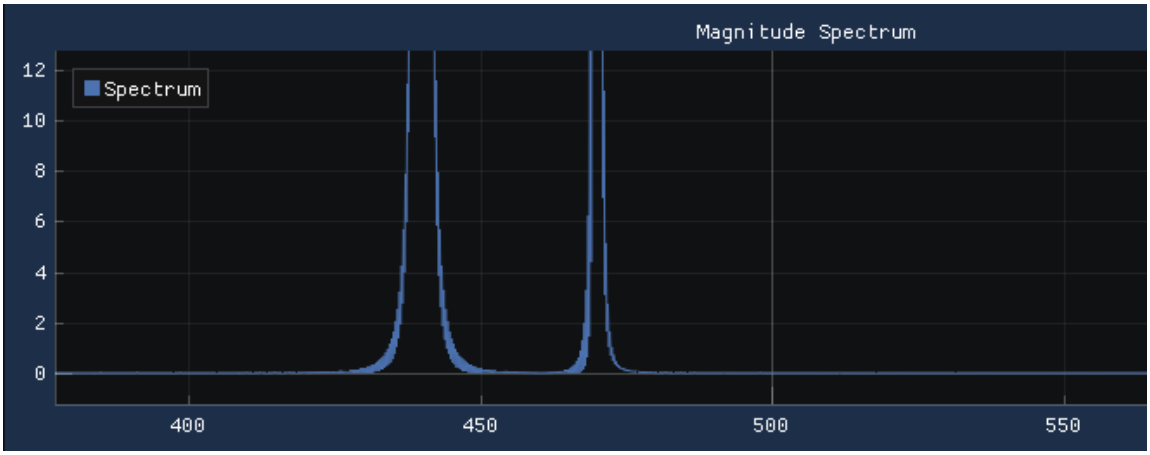

Rysunek 24. Widmo amplitudowe sygnału 440 Hz, $A = 0{,}5$ oraz 470 Hz, $A = 0{,}05$ dla okna Hanna.

Dla okna Hanna widmo jest wyraźnie czystsze niż dla okna Hamminga. Na wykresie widać dwa dobrze oddzielone piki odpowiadające częstotliwościom 440 Hz oraz 470 Hz. Słabsza składowa o częstotliwości 470 Hz jest dobrze widoczna mimo dziesięciokrotnie

mniejszej amplitudy.

W porównaniu z oknem Hamminga znacząco zmniejszyły się boczne oscylacje wokół głównych składowych. Energia widma jest bardziej skupiona przy rzeczywistych częstotliwościach sygnału, a tło pomiędzy i poza pikami ma mniejszą amplitudę. Oznacza to, że okno Hanna lepiej ograniczyło widoczny przeciek widmowy i ułatwiło odróżnienie słabszego tonu od silniejszego.

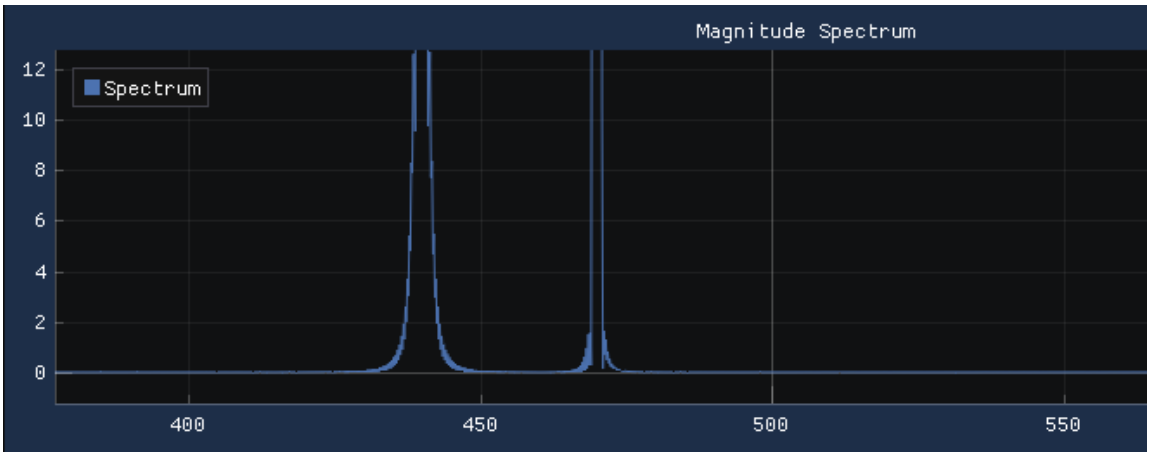

Rysunek 25. Widmo amplitudowe sygnału 440 Hz, $A = 0{,}5$ oraz 470 Hz, $A = 0{,}05$ dla okna Blackmana.

Dla okna Blackmana otrzymano wynik bardzo podobny do okna Hanna. Na wykresie widoczne są dwa wyraźnie oddzielone piki odpowiadające częstotliwościom 440 Hz oraz 470 Hz. Słabsza składowa o częstotliwości 470 Hz pozostaje dobrze widoczna mimo znacznie mniejszej amplitudy. W analizowanym przypadku różnice między oknem Hanna i Blackmana nie są duże — oba okna skutecznie ograniczają widoczny przeciek widmowy i pozwalają czytelnie zauważyć słabszą składową.

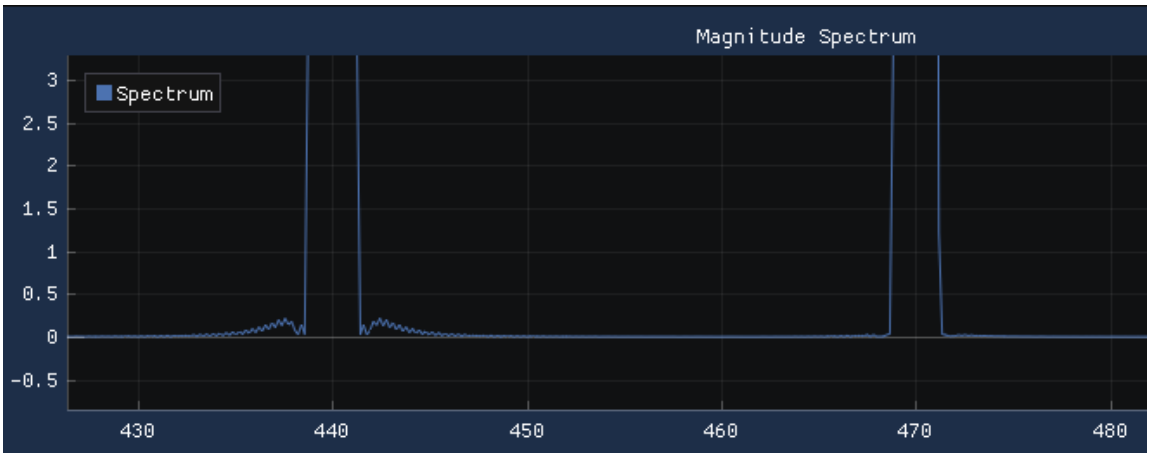

Rysunek 26. Widmo amplitudowe sygnału 440 Hz, $A = 0{,}5$ oraz 470 Hz, $A = 0{,}05$ dla okna Nuttalla.

Dla okna Nuttalla otrzymano bardzo czytelne widmo. Energia jest skupiona głównie w pobliżu rzeczywistych składowych sygnału, a prążki boczne są słabo widoczne. Dzięki temu słabszy składnik o częstotliwości 470 Hz jest dobrze odróżnialny od przecieku pochodzącego od silniejszej składowej 440 Hz.

4.4 Porównanie wyznaczania F_0 metodą cepstralną oraz autokorelacyjną

Celem eksperymentu było porównanie sposobu wyznaczania częstotliwości podstawowej F_0 w aktualnej aplikacji oraz w poprzedniej wersji programu. W aktualnej aplikacji F_0 jest wyznaczane metodą cepstralną, natomiast w starszej wersji wykorzystywana była metoda autokorelacji.

Do testu przygotowano sztuczny sygnał harmoniczny w programie Audacity. Sygnał nie zawierał bezpośrednio składowej o częstotliwości podstawowej, lecz składał się z jej kolejnych harmonicznych. W osobnych ścieżkach wygenerowano sinusoidy o częstotliwościach:

$$300 \text{ Hz}, \quad 450 \text{ Hz}, \quad 600 \text{ Hz}, \quad 750 \text{ Hz}$$

Następnie ścieżki zostały połączone za pomocą opcji *Mix and Render*. Tak przygotowany sygnał jest przykładem przypadku, w którym częstotliwość podstawowa nie występuje bezpośrednio w widmie, ale można ją wywnioskować z odstępu pomiędzy kolejnymi harmonicznymi. Ponieważ kolejne składowe są oddalone od siebie o 150 Hz, oczekiwana częstotliwość podstawowa wynosi:

$$F_0 = 150 \text{ Hz}$$

Taki przypadek jest interesujący, ponieważ pozwala sprawdzić, czy metoda potrafi wyznaczyć F_0 na podstawie struktury harmonicznej sygnału, a nie tylko na podstawie obecności najniższej składowej częstotliwościowej.

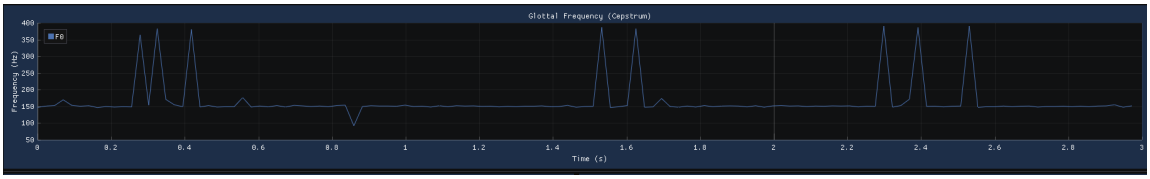

Rysunek 27. Przebieg częstotliwości podstawowej F_0 wyznaczonej metodą cepstralną dla sygnału złożonego ze składowych 300 Hz, 450 Hz, 600 Hz oraz 750 Hz.

Na wykresie przedstawiono wartości F_0 wyznaczone metodą cepstralną w kolejnych ramkach czasowych. Przez większość czasu wynik utrzymuje się w pobliżu wartości 150 Hz, czyli oczekiwanej częstotliwości podstawowej badanego sygnału. Oznacza to, że metoda cepstralna poprawnie rozpoznała okresowość wynikającą z regularnego odstępu między harmonicznymi, mimo że w sygnale nie było bezpośrednio składowej 150 Hz.

Na wykresie widoczne są jednak pojedyncze skoki wartości F_0 do zakresu około 350–400 Hz oraz jeden spadek poniżej wartości oczekiwanej. Można je traktować jako błędne detekcje w pojedynczych ramkach, wynikające z wyboru niewłaściwego maksimum cepstrum. Mimo tych lokalnych błędów dominująca część przebiegu znajduje się blisko 150 Hz, więc metoda cepstralna w większości ramek poprawnie wyznaczyła częstotliwość podstawową.

Ten sam sygnał został następnie przeanalizowany w starszej wersji aplikacji, w której częstotliwość podstawowa F_0 była wyznaczana metodą autokorelacji oraz metodą AMDF.

W starej aplikacji wartości F_0 były prezentowane w kHz, dlatego oczekiwana wartość 150 Hz odpowiada:

$$150 \text{ Hz} = 0{,}15 \text{ kHz}$$

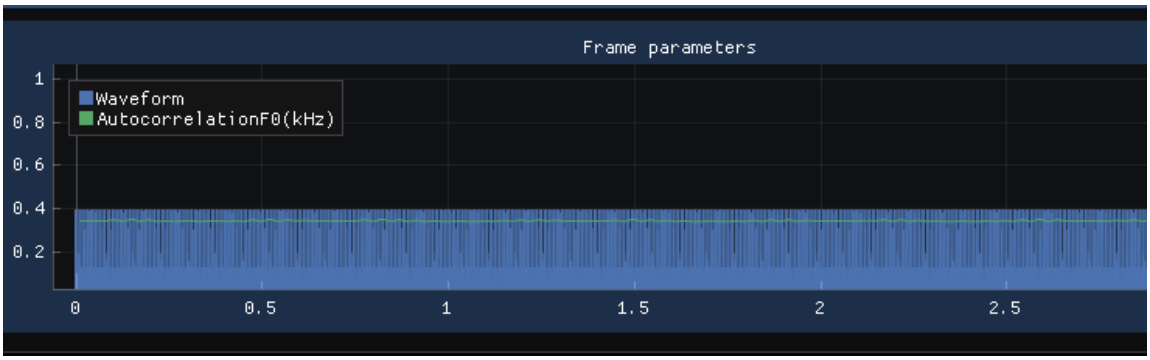

Rysunek 28. Przebieg częstotliwości podstawowej F_0 wyznaczonej metodą autokorelacji dla sygnału złożonego ze składowych 300 Hz, 450 Hz, 600 Hz oraz 750 Hz.

Na wykresie dla metody autokorelacji wartość F_0 utrzymuje się w przybliżeniu w okolicach 0,35–0,4 kHz, czyli około 350–400 Hz. Wynik ten jest znacznie wyższy od oczekiwanej wartości 0,15 kHz. Oznacza to, że metoda autokorelacji w tej implementacji nie rozpoznała poprawnie częstotliwości podstawowej wynikającej z odstępu między harmonicznymi. Zamiast tego wskazała wartość związaną raczej z jedną z obecnych składowych lub lokalną okresowością sygnału.

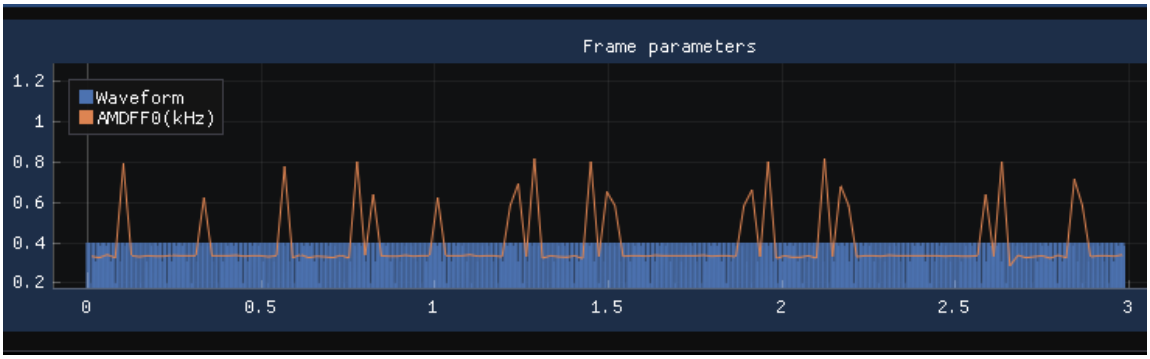

Rysunek 29. Przebieg częstotliwości podstawowej F_0 wyznaczonej metodą AMDF dla sygnału złożonego ze składowych 300 Hz, 450 Hz, 600 Hz oraz 750 Hz.

Dla metody AMDF wynik był jeszcze mniej stabilny niż dla autokorelacji. Wartość F_0 przez część czasu znajdowała się w okolicy około 0,3–0,4 kHz, ale pojawiały się również liczne skoki do wyższych wartości, dochodzące miejscami do około 0,7–0,8 kHz. Oznacza to, że metoda AMDF również nie wyznaczyła poprawnie oczekiwanego $F_0 = 0{,}15$ kHz i dodatkowo dawała bardziej niestabilny przebieg.

Porównując wszystkie trzy metody, można zauważyć wyraźną różnicę w jakości estymacji F_0. Dla sygnału złożonego ze składowych 300 Hz, 450 Hz, 600 Hz oraz 750 Hz oczekiwana częstotliwość podstawowa wynosiła 150 Hz, czyli 0,15 kHz. Metoda cepstralna w większości ramek wskazywała wartość bliską 150 Hz, mimo że składowa o tej częstotliwości nie

występowała bezpośrednio w sygnale. Oznacza to, że cepstrum poprawnie wykorzystało regularny odstęp między harmonicznymi.

Metoda autokorelacji dawała wynik dość stabilny, ale zawyżony – najczęściej w okolicy 0,35–0,4 kHz. Z kolei metoda AMDF była mniej stabilna i oprócz zawyżonych wartości generowała liczne skoki. W tym eksperymencie metoda cepstralna najlepiej poradziła sobie z przypadkiem brakującej częstotliwości podstawowej, natomiast autokorelacja i AMDF częściej wskazywały wartości związane prawdopodobnie z obecnymi harmonicznymi lub lokalną okresowością sygnału, zamiast oczekiwanego F_0.

4.5 Zmiana tonu podstawowego u jednego lektora dla różnych słów

Celem eksperymentu było sprawdzenie, jak zmienia się częstotliwość podstawowa F_0 dla jednego lektora w zależności od wypowiadanego słowa. Do analizy wybrano nagrania tej samej osoby, ale zawierające słowa o różnej budowie fonetycznej: „zero”, „chrząszcz”, „dum” oraz „bub”. Dzięki temu można było porównać przebieg F_0 zarówno dla słów zawierających głównie fragmenty dźwięczne, jak i dla słowa z dużą liczbą głosek szumiących oraz bezdźwięcznych.

Częstotliwość podstawowa została wyznaczona metodą cepstralną. Należy pamiętać, że F_0 ma sens głównie dla fragmentów dźwięcznych mowy, czyli takich, w których występują regularne drgania fałdów głosowych. Dla spółgłosek bezdźwięcznych i szumiących wynik może być niestabilny lub błędny, ponieważ sygnał ma wtedy bardziej szumowy charakter i nie zawiera jednoznacznego tonu podstawowego.

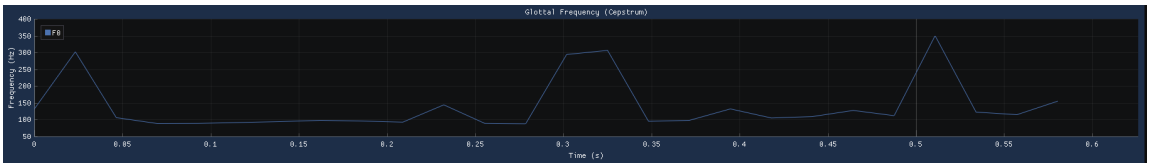

Rysunek 30. Przebieg częstotliwości podstawowej F_0 wyznaczonej metodą cepstralną dla słowa „zero”.

Na rysunku 30 przedstawiono przebieg częstotliwości podstawowej F_0 dla słowa „zero”. Przez znaczną część nagrania wartości F_0 znajdują się w zakresie około 90–150 Hz, co można interpretować jako prawdopodobny zakres tonu podstawowego dla tego lektora w danym nagraniu.

Na wykresie widoczne są jednak również pojedyncze skoki do wyższych wartości, sięgające około 300–350 Hz. Można je traktować jako lokalne błędne detekcje metody cepstralnej lub efekt wyboru niewłaściwego maksimum cepstrum. Takie skoki mogą pojawiać się szczególnie w krótkich fragmentach przejściowych między głoskami, gdzie sygnał nie ma stabilnej okresowości.

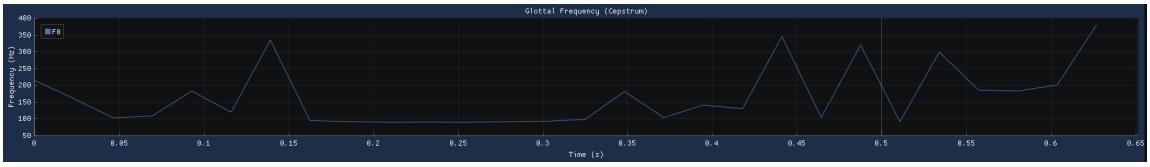

Rysunek 31. Przebieg częstotliwości podstawowej F_0 wyznaczonej metodą cepstralną dla słowa „chrząszcz”.

Na rysunku 31 przedstawiono wynik dla słowa „chrząszcz”. W porównaniu ze słowem „zero” przebieg jest wyraźnie mniej stabilny. Wartości F_0 często zmieniają się skokowo i pojawiają się przejścia do wysokich wartości, miejscami zbliżonych do górnej granicy analizowanego zakresu.

Jest to zgodne z budową fonetyczną słowa „chrząszcz”, które zawiera wiele głosek szumiących i bezdźwięcznych. Dla takich fragmentów sygnał ma charakter bardziej szumowy i nie zawiera stabilnej częstotliwości podstawowej. W efekcie metoda cepstralna może wybierać lokalne maksimum cepstrum, które nie odpowiada rzeczywistemu tonowi krtaniowemu. Najbardziej wiarygodne wartości F_0 należy więc interpretować głównie dla fragmentów dźwięcznych, np. samogłoski „ą”.

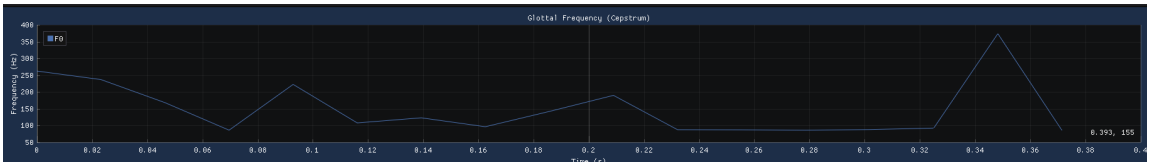

Rysunek 32. Przebieg częstotliwości podstawowej F_0 wyznaczonej metodą cepstralną dla słowa „dum”.

Na rysunku 32 przedstawiono przebieg F_0 dla słowa „dum”. W porównaniu ze słowem „chrząszcz” wynik jest łatwiejszy do interpretacji, ponieważ słowo „dum” składa się głównie z głosek dźwięcznych. W znacznej części nagrania wartości F_0 mieszczą się w zakresie około 90–190 Hz, co można traktować jako prawdopodobny zakres tonu podstawowego dla tego lektora.

Na wykresie widoczne są jednak również skoki do wyższych wartości, szczególnie na początku oraz pod koniec nagrania. Mogą one wynikać z krótkiego czasu trwania słowa, przejść między głoskami oraz wyboru niewłaściwego maksimum cepstrum w pojedynczych ramkach. Mimo tych lokalnych niestabilności wynik dla słowa „dum” jest bardziej miarodajny niż dla słowa zawierającego wiele głosek szumiących, ponieważ większa część analizowanego sygnału ma charakter dźwięczny.

Rysunek 33. Przebieg częstotliwości podstawowej F_0 wyznaczonej metodą cepstralną dla słowa „bub”.

Na rysunku 33 przedstawiono przebieg F_0 dla słowa „bub”. Podobnie jak w przypadku słowa „dum”, słowo to składa się głównie z głosek dźwięcznych. Przez część nagrania

wartości F_0 znajdują się w zakresie około 90–140 Hz, co można uznać za prawdopodobny zakres tonu podstawowego dla tego lektora.

Jednocześnie widoczne są skoki do wyższych wartości, miejscami powyżej 300 Hz. Mogą one wynikać z krótkiego czasu trwania nagrania, przejść między spółgłoskami i samogłoską oraz lokalnego wyboru niewłaściwego maksimum cepstrum. W porównaniu ze słowem „chrząszcz” przebieg jest jednak łatwiejszy do interpretacji, ponieważ większa część sygnału ma charakter dźwięczny.

Porównanie czterech słów pokazuje, że F_0 dla jednego lektora nie jest wartością stałą w całym nagraniu. Dla słów zawierających więcej fragmentów dźwięcznych, takich jak „dum” i „bub”, przebieg jest łatwiejszy do interpretacji i częściej mieści się w typowym zakresie tonu podstawowego dla badanego głosu. Dla słowa „zero” również widoczne są fragmenty o sensownych wartościach F_0, ale pojawiają się lokalne skoki związane najprawdopodobniej z przejściami między głoskami.

Najbardziej niestabilny wynik uzyskano dla słowa „chrząszcz”, które zawiera wiele głosek szumiących i bezdźwięcznych. W takich fragmentach nie występuje jednoznaczny ton podstawowy, dlatego metoda cepstralna może zwracać przypadkowe lub zawyżone wartości. Eksperyment potwierdza więc, że wyznaczanie F_0 metodą cepstralną jest najbardziej wiarygodne dla fragmentów dźwięcznych mowy, natomiast dla głosek bezdźwięcznych i szumowych wynik należy interpretować ostrożnie.

4.6 Spektogramy różnych słów

Postanowiono zbadać też wygląd spektogramów dla różnych słów, składających się zarówno z samogłosek, spółgłosek, dźwięcznych, bezdźwięcznych, syczących i wybuchowych.

Pierwszym słowem poddanym analizie było „gyr”, przedstawione na Rysunku 34.

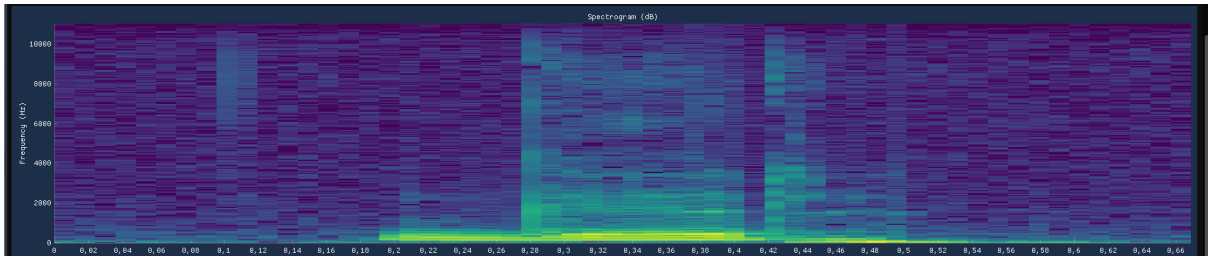

Rysunek 34. Spektogram słowa „gyr”

Zauważono, iż wyraźnie samogłoska w środku ma energię skupioną na szerszym paśmie niż otaczające ją spółgłoski.

Kolejnym słowem był „chrząszcz”. Wynik przedstawia Rysunek 35.

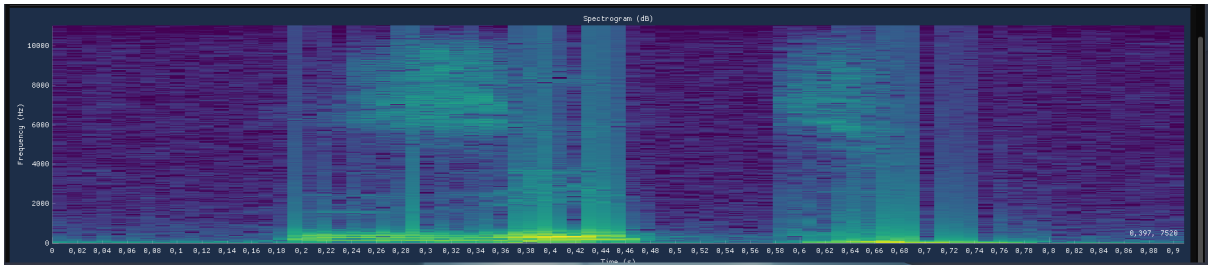

Rysunek 36. Spektogram słowa „zit”

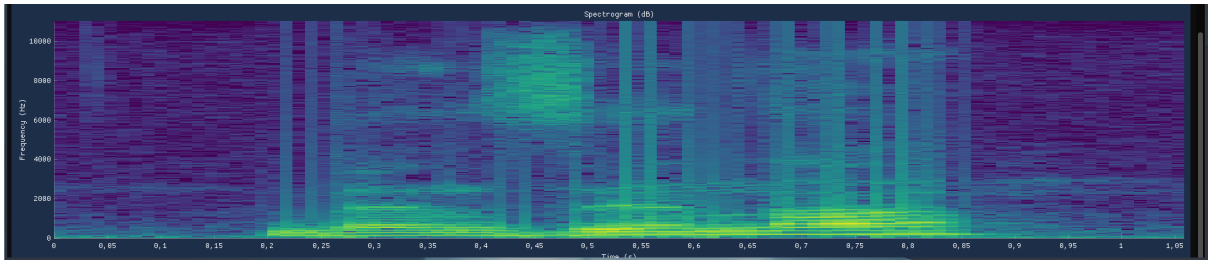

Rysunek 37. Spektogram słowa „benzyna”

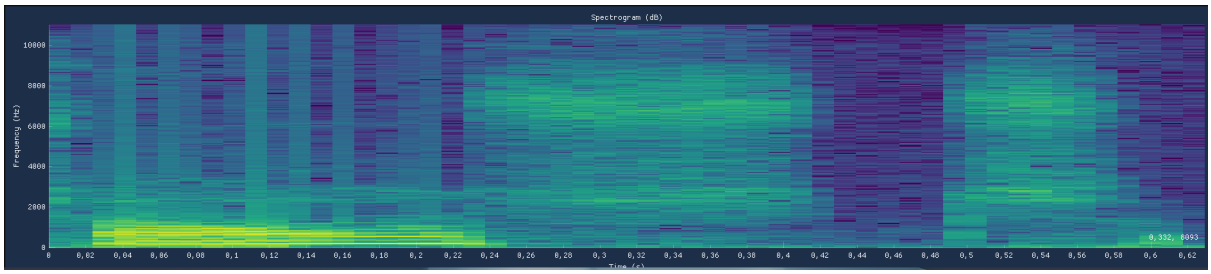

Rysunek 35. Spektogram słowa „chrząszcz”

Również zauważono skupienie energii na dużym obszarze dla samogłoski „ą” oraz ciekawy wynik dla spółgłosek syczących. Na spektogramie wyglądają one jak takie chmurki. Jest to spodziewana cecha takich głosek - nie mają one tonu podstawowego, lecz bardziej charakter przefiltrowanego białego szumu, gdyż są one wynikiem przepychania powietrza przez wąską szczelinę, a nie wytworem strun głosowych.

Kolejno zbadano pod kątem głoski wybuchowej słowo „zit”. Wynik przedstawia Rysunek 36.

Zauważono znów szersze skupienie energii dla samogłoski niż dla spółgłoski oraz charakterystyczny obraz dla „t” - czarna cisza po której następują jasne pasy na spektogramie w miejscu, gdzie następuje wybuch (trochę zniekształcony).

Ostatnim przedmiotem badań było słowo „benzyna” aby zobaczyć, czy faktycznie na spektogramie skupienie energii będzie „pływać” pomiędzy samogłoskami i spółgłoskami. Wynik przedstawia Rysunek 37.

Z tego spektogramu widać zauważalne różnice w szerokości skupienia energii na spektogramie dla poszczególnych głosek. Dodatkowo nad „z” pojawiła się mała chmurka.

5 Wnioski

5.1 Zbadanie wpływu funkcji okienkowych

Eksperyment bliskich częstotliwości

Na podstawie przeprowadzonego eksperymentu można stwierdzić, że wybór funkcji okienkowej wyraźnie wpływa na postać widma amplitudowego analizowanego sygnału. Dla wszystkich okien główne składowe sygnału są widoczne w pobliżu częstotliwości 440 Hz oraz 445 Hz, jednak różnice między oknami dotyczą przede wszystkim tego, jak dużo energii pojawia się poza tym głównym obszarem widma.

Największy przeciek widmowy zaobserwowano dla okna prostokątnego. Na powiększonym dolnym wykresie widoczna jest duża liczba oscylacji i prążków bocznych, a energia sygnału rozlewa się na szeroki zakres częstotliwości. Okno trójkątne ogranicza ten efekt w porównaniu z oknem prostokątnym, jednak nadal widoczne jest pewne rozciągnięcie energii wokół głównych składowych.

Dla okna Hamminga główny wykres wygląda znacznie czyściej, ponieważ przy większych wartościach amplitudy widoczne są głównie prążki odpowiadające analizowanym częstotliwościom. Dopiero po powiększeniu dolnej części widma można zauważyć słabsze oscylacje i prążki boczne. Oznacza to, że przeciek widmowy nie znika całkowicie, ale ma dużo mniejszą amplitudę niż w przypadku okna prostokątnego.

Okna Hanna i Blackmana dały bardzo podobne wyniki. W obu przypadkach widmo jest skupione głównie w pobliżu częstotliwości 440 Hz oraz 445 Hz, a po powiększeniu dolnej części wykresu widać jedynie niewielkie rozlanie energii wokół głównych składowych. Przeciek widmowy jest więc wyraźnie mniejszy niż dla okna prostokątnego i Hamminga.

Najczystsze widmo otrzymano dla okna Nuttalla. Zarówno na wykresie w szerszym zakresie amplitudy, jak i na powiększonej dolnej części widma energia pozostaje skupiona praktycznie wyłącznie w pobliżu głównych częstotliwości. Nie widać wyraźnych prążków bocznych oddalonych od głównych składowych, dlatego w tym eksperymencie okno Nuttalla najlepiej ograniczyło widoczny przeciek widmowy.

Eksperyment pokazuje również, że różnice między funkcjami okienkowymi nie zawsze są dobrze widoczne na wykresie w pełnej skali amplitudy, ponieważ główne składowe mają dużo większą amplitudę niż prążki boczne. Dlatego do oceny przecieku widmowego szczególnie przydatne było powiększenie dolnej części widma. W przypadku bardzo bliskich częstotliwości, takich jak 440 Hz i 445 Hz, najważniejszą obserwacją nie jest idealne rozdzielenie dwóch pojedynczych pików, lecz porównanie tego, jak poszczególne okna ograniczają energię pojawiającą się poza głównym obszarem widma.

Eksperyment różnych amplitud

Na podstawie eksperymentu można stwierdzić, że funkcja okienkowa ma duże znaczenie w sytuacji, gdy w sygnale występują składowe o wyraźnie różnych amplitudach. W analizowanym przypadku silniejsza składowa miała częstotliwość 440 Hz i amplitudę 0,5, natomiast słabsza składowa miała częstotliwość 470 Hz i amplitudę 0,05. Oznacza to, że drugi ton miał dziesięciokrotnie mniejszą amplitudę, przez co mógł zostać zamaskowany

przez przeciek widmowy pochodzący od silniejszej składowej.

Najgorszy wynik uzyskano dla okna prostokątnego. W jego przypadku energia silniejszej składowej rozlewała się na szeroki zakres częstotliwości, a w widmie pojawiało się wiele oscylacji i prążków bocznych. Słabsza składowa o częstotliwości 470 Hz nie była widoczna jako osobny, wyraźny pik, ponieważ znajdowała się w obszarze przecieku pochodzącego od tonu 440 Hz.

Okno trójkątne poprawiło czytelność widma w porównaniu z oknem prostokątnym. Energia silniejszej składowej była bardziej skupiona w pobliżu głównego piku, a słabszy ton przy 470 Hz stał się wyraźniej widoczny. Nadal jednak można było zauważyć pewne boczne oscylacje wokół głównych częstotliwości.

Dla okna Hamminga wynik był zbliżony do okna trójkątnego i wyraźnie lepszy niż dla okna prostokątnego. Słabsza składowa była już widoczna obok silniejszej, jednak w widmie nadal występowały boczne oscylacje, co oznacza, że przeciek widmowy nie został całkowicie usunięty.

Najbardziej czytelne wyniki uzyskano dla okien Hanna, Blackmana i Nuttalla. Dla okna Hanna widoczne były dwa dobrze oddzielone piki odpowiadające częstotliwościom 440 Hz oraz 470 Hz, a boczne oscylacje były znacznie mniejsze niż dla okna Hamminga. Okno Blackmana dało bardzo podobny rezultat do okna Hanna — słabsza składowa pozostała dobrze widoczna, a widoczny przeciek był niewielki. Dla okna Nuttalla widmo było również bardzo czytelne, a prążki boczne były słabo widoczne.

Eksperyment pokazuje, że ograniczenie przecieku widmowego jest szczególnie ważne przy wykrywaniu słabszych składowych znajdujących się w pobliżu silniejszych tonów. Okno prostokątne może utrudniać ich zauważenie, ponieważ przeciek od silnej składowej maskuje słabszy pik. Okna wygładzające, zwłaszcza Hann, Blackman i Nuttall, znacznie poprawiają czytelność widma i ułatwiają odróżnienie słabszej składowej od tła.

5.2 Wnioski z analizy parametrów w dziedzinie częstotliwości

Przeprowadzone eksperymenty wykazały, że parametry wyznaczane na poziomie ramki w dziedzinie częstotliwości (Frame-Level Features) stanowią skuteczne narzędzie do dyskryminacji różnych typów dźwięków w sygnale mowy. Na podstawie analizy 24 wykresów dla różnych słów i mówców sformułowano następujące wnioski:

- **Rozróżnianie głosek dźwięcznych i bezdźwięcznych:** Parametry takie jak Miara Płaskości Widma (SFM) oraz Spektralny Współczynnik Szczytu (SCF) doskonale korelują z charakterem głoski. Głoski dźwięczne (w tym samogłoski) charakteryzują się bardzo niskim SFM (bliskim 0) oraz wysokim SCF, co potwierdza ich silnie tonalną strukturę z dominującymi rezonansami. Z kolei spółgłoski szumiące (np. „sz”, „cz”) wykazują wysokie wartości SFM oraz niski SCF, upodabniając się swoimi parametrami do szumu białego.

- **Ocena „jasności” dźwięku i zjawisko samogłoski „i”:** Środek ciężkości widma (FC) oraz Efektywne pasmo (BW) pozwalają na skuteczne odróżnienie ciemnych samogłosek (jak „u”, „o”, „a”, gdzie energia skupiona jest w dolnych pasmach, dając niskie wartości FC i BW) od głosek o wysokiej częstotliwości (spółgłoski szumiące). Istotnym odkryciem było zidentyfikowanie anomalii dla samogłoski „i”, która mimo

bycia głoską dźwięczną, osiąga bardzo wysokie wartości FC i BW. Wynika to z jej specyficznej budowy anatomiczno-akustycznej – ogromnego dystansu między bardzo niskim formantem F_1 a bardzo wysokim formantem F_2.

- **Zmienność osobnicza:** Parametry częstotliwościowe są silnie uzależnione od cech lektora. Zaobserwowano, że dla głosów żeńskich wartości parametrów (szczególnie FC dla spółgłosek) przyjmują zazwyczaj wyższe wartości niż dla głosów męskich, co jest bezpośrednim wynikiem różnic w długości i budowie traktu głosowego.

5.3 Wnioski z analizy formantów

Badanie widm amplitudowych (FFT) z wykorzystaniem okna Hamminga pozwoliło na wizualną identyfikację i oszacowanie wartości częstotliwości rezonansowych (formantów) dla podstawowych polskich samogłosek.

- **Zgodność z danymi literaturowymi:** Zidentyfikowane z wykresów wartości dwóch pierwszych formantów (F_1 i F_2) dla samogłosek „a”, „i”, „o”, „u” w większości przypadków pokrywały się lub były bardzo bliskie uśrednionym wartościom tablicowym. Największą stabilność i zgodność zauważono dla pierwszego formantu (F_1), podczas gdy drugi formant (F_2) częściej ulegał drobnym odchyleniom.

- **Wpływ koartykulacji i kontekstu:** Udowodniono, że widmo amplitudowe dla tej samej samogłoski u tego samego lektora nie jest stałe. Wartości formantów, a w szczególności kształt wyższych składowych harmonicznych, wykazują dużą zmienność w zależności od miejsca wystąpienia w słowie i sąsiadujących z nią spółgłosek. Najbardziej stabilną strukturę pod tym względem zaobserwowano dla samogłoski „u”.

- **Różnice międzyosobnicze:** Potwierdzono empirycznie zjawisko unikalności traktu głosowego. Porównanie widm amplitudowych tej samej samogłoski wymawianej przez różnych lektorów ujawniło znaczące różnice w położeniu formantów oraz dystrybucji energii na poszczególnych harmonicznych. Oznacza to, że analiza formantowa na poziomie wyższych rezonansów może stanowić wiarygodne narzędzie w systemach rozpoznawania mówcy (Speaker Identification).

5.4 Wnioski z analizy spektrogramów

Na podstawie wizualnej oceny wygenerowanych spektrogramów dla zróżnicowanego materiału badawczego (słowa: „gyr”, „chrząszcz”, „zit”, „benzyna”), sformułowano następujące wnioski potwierdzające użyteczność tej reprezentacji w analizie fonetycznej:

- **Identyfikacja samogłosek:** Samogłoski odznaczają się na spektrogramie najwyższą energią, która jest skupiona w wąskich, wyraźnych pasmach (formantach). Zgodnie z obserwacjami, tworzą one dominujące, poziome struktury, które wyraźnie kontrastują z otaczającymi je spółgłoskami.

- **Charakterystyka spółgłosek szumiących i syczących:** Głoski szczelinowe i zwarto-szczelinowe (np. „sz”, „cz”, „ch”) wizualizują się jako nieuporządkowane

„chmury” szumu. Zjawisko to potwierdza ich fizyczną naturę – brak w nich drgań strun głosowych (tonu podstawowego), a dźwięk powstaje jako szum turbulencyjny. Ich energia jest zazwyczaj rozproszona w wyższych rejestrach częstotliwościowych.

- **Sygnatura spółgłosek wybuchowych:** Fonemy takie jak „t” wykazują unikalny, dwufazowy obraz na spektrogramie. Pierwszą fazą jest faza zwarcia narządów mowy, widoczna jako wyraźna, ciemna przerwa (cisza akustyczna). Bezpośrednio po niej następuje faza plozji (wybuchu), rejestrowana jako ostry, szerokopasmowy pionowy prążek (transjent).
- **Dynamika i płynność mowy:** Analiza wielosylabowych słów, takich jak „benzyna”, doskonale ukazuje zjawisko koartykulacji i płynnego „pływania” energii. Spektrogram pozwala precyzyjnie zaobserwować, jak szerokopasmowa energia samogłosek przechodzi w cichsze, węższe pasma spółgłosek dźwięcznych (np. „n”), a niekiedy nakłada się na obszary zaszumione (np. dźwięczne, ale szczelinowe „z”).

Podsumowując, spektrogram stanowi znakomite i wysoce intuicyjne narzędzie diagnostyczne. Pozwala on na błyskawiczną, wzrokową klasyfikację typów fonemów, stanowiąc idealne dopełnienie i potwierdzenie dla parametrów wyznaczanych liczbowo (takich jak środek ciężkości czy miara płaskości widma).